



ALMA MATER STUDIORUM · UNIVERSITÀ DI BOLOGNA

DIPARTIMENTO DI INFORMATICA — SCIENZA E INGEGNERIA

Corso di Laurea in Ingegneria e Scienze Informatiche

Sviluppo di un modello di Deep Learning per il rilevamento del malposizionamento degli elettrodi in un ECG a 12 derivazioni

Tesi di Laurea in Metodi Numerici

Relatrice:

Prof.ssa Damiana Lazzaro

Presentata da:

Nicholas Benedetti

Correlatore:

Prof. Johannes De Bie

Sessione Unica
Anno Accademico 2025/2026

Indice

1	Elettrocardiografia e basi elettrofisiologiche	5
1.1	Anatomia ed elettrofisiologia del Cuore	5
1.1.1	La parete cardiaca	7
1.1.2	Contrazione e composizione cellulare	8
1.1.3	Il Ciclo Cardiaco	9
1.1.4	Elettrofisiologia	10
1.2	ECG a 12 derivazioni	13
1.2.1	Posizionamento degli elettrodi	13
1.2.2	Calcolo delle Derivazioni	14
1.2.3	Visibilità	16
1.2.4	Lettura ECG	18
2	Stato dell'arte	21
2.1	Metodi classici basati su regole	21
2.1.1	Scambi degli elettrodi periferici	21
2.1.2	Scambi degli elettrodi precordiali	23
2.1.3	Limiti dei metodi classici	23
2.2	Approcci basati su apprendimento automatico e deep learning . . .	24
2.3	Posizionamento del presente lavoro	25
3	Basi matematiche ed elaborazione del segnale	27
3.1	Fondamenta matematiche	27
3.1.1	Fondamenti matematici per l'analisi dei segnali	27
3.1.2	Spline	33
3.1.3	Filtri lineari e funzione di trasferimento	35

3.2	Segnale ECG digitale	40
3.2.1	Campionamento e segnale discreto	40
3.2.2	Preprocessing e filtraggio	42
4	Dataset e simulazione degli scambi	47
4.1	Database di partenza	48
4.1.1	Il database PTB-XL	48
4.1.2	Il database Georgia	50
4.2	Pipeline di costruzione del dataset	51
4.3	Suddivisione in training, validazione e test	52
4.3.1	Proporzioni e procedura	53
4.4	Segmentazione beat-by-beat	53
4.4.1	Rilevamento dei picchi R	54
4.4.2	Estrazione della finestra	55
4.4.3	Numero di battiti estratti: differenza tra train/val e test . .	56
4.5	Simulazione degli scambi di elettrodi	57
4.5.1	Perché è necessaria una simulazione	57
4.5.2	Equazioni delle derivazioni standard	58
4.5.3	Effetto di uno scambio di elettrodi	59
4.5.4	Regole di generazione del dataset finale	63
4.6	Struttura del dataset finale	64
4.7	Terzo database solo per il test	65
4.7.1	Preparazione dei dati	66
4.7.2	Utilizzo nella valutazione	67
5	Architetture proposte	69
5.1	Multi-Layer Perceptron	69
5.1.1	Funzioni di Attivazione	70
5.1.2	Funzione di Loss	70
5.1.3	Fondamenta matematiche	71
5.1.4	Algoritmo di Backpropagation	73
5.1.5	Calcolo del Gradiente in un MLP	74
5.2	Convolutional Neural Network	76
5.2.1	Architettura di una CNN	77

5.2.2	Calcolo del gradiente in una CNN	78
5.2.3	CNN applicate a segnali monodimensionali	81
5.2.4	Vantaggi per i segnali ECG	82
5.3	Graph Convolutional Network con CNN Backbone	82
5.3.1	Estrazione delle feature nodali	83
5.3.2	Modellazione del Grafo ECG basata su Vettori di Derivazio- ne 3D	85
5.3.3	Costruzione del Grafo Signed	87
5.3.4	Message Passing Signed	88
5.3.5	Calcolo del Gradiente nella GCN	88
5.3.6	Pooling Globale e Classificazione	91
6	Validazione sperimentale e risultati	93
6.1	Metodologia di valutazione	93
6.2	Pulizia del training set	95
6.3	Configurazioni sperimentali	96
6.4	Risultati numerici	98
6.4.1	split di test tra modelli	98
6.4.2	split di test tra <i>original</i> e <i>reduced</i>	99
6.4.3	database esterno	99
6.4.4	database esterno modificato	100
6.4.5	modifica della soglia	104
7	Discussione dei risultati	105
8	Conclusioni e sviluppi futuri	111
8.1	Conclusioni	111
8.2	Sviluppi futuri	113

Sommario

L'elettrocardiogramma a 12 derivazioni rimane lo strumento diagnostico più diffuso per la valutazione dell'attività elettrica cardiaca, ma la sua affidabilità clinica dipende criticamente dal corretto posizionamento degli elettrodi. Errori come lo scambio di elettrodi periferici o il malposizionamento di quelli precordiali sono tutt'altro che rari nella pratica clinica e possono generare tracciati "plausibili" ma clinicamente fuorvianti, in grado di simulare patologie inesistenti o mascherarne di reali, con conseguenze rilevanti per la sicurezza del paziente e per i costi sanitari.

Questo lavoro propone un sistema automatico per il rilevamento del malposizionamento degli elettrodi a partire da un singolo tracciato ECG a 12 derivazioni, senza necessità di un tracciato di riferimento acquisito correttamente sullo stesso paziente. Il contributo si articola su tre livelli. In primo luogo, viene sviluppata una pipeline di simulazione degli scambi di elettrodi basata sulle relazioni algebriche tra le derivazioni standard e i potenziali dei singoli elettrodi (leggi di Einthoven e Goldberger, terminale centrale di Wilson), che consente di generare, a partire da database pubblici (PTB-XL e Georgia), un dataset ampio ed etichettato in modo affidabile. In secondo luogo, vengono progettate e confrontate tre architetture di deep learnin: un modello ibrido CNN+GCN, che integra l'estrazione di feature morfologiche per singola derivazione con una rete a grafo capace di modellare le relazioni spaziali tra le derivazioni, una CNN pura e un MLP. In terzo luogo, i modelli proposti vengono validati sperimentalmente su un insieme di test bilanciato, con un'analisi delle prestazioni complessive, e uno studio finale basato sull'analisi di specificità e sensibilità. Infine i risultati ottenuti vengono discussi criticamente, evidenziando i limiti legati all'uso di un dataset sintetico.

Introduzione

Il problema del malposizionamento degli elettrodi

L'elettrocardiogramma a 12 derivazioni è, ancora oggi, lo strumento diagnostico più diffuso ed economico per la valutazione dell'attività elettrica del cuore, ed è alla base della diagnosi di un ampio spettro di patologie cardiovascolari. La sua affidabilità clinica dipende però in modo critico dalla corretta esecuzione del posizionamento dei dieci elettrodi sulla superficie corporea del paziente, secondo lo standard descritto nella sezione 1.2.1.

Nella pratica clinica quotidiana, questo posizionamento non è sempre eseguito correttamente. Lo scambio di due elettrodi periferici (ad esempio: braccio destro e braccio sinistro) o il posizionamento non corretto di uno o più elettrodi precordiali sono errori tutt'altro che rari: la letteratura riporta un'incidenza di malposizionamento che, a seconda del contesto di acquisizione e della tipologia di errore considerata, varia indicativamente da meno dell'1% fino a diversi punti percentuali dei tracciati registrati. Il problema però, è molto più subdolo: un elettrodo scambiato può alterare in modo sostanziale la morfologia delle onde P, del complesso QRS e dell'onda T, fino a simulare quadri patologici inesistenti (ad esempio un infarto anteriore o un pattern di tipo Brugada) oppure, viceversa, a mascherare un'alterazione realmente presente. Le conseguenze cliniche di una diagnosi errata derivante da un tracciato mal acquisito possono essere significative,

sia in termini di sicurezza del paziente sia in termini di costi sanitari legati ad accertamenti diagnostici superflui.

A differenza di altri artefatti che affliggono il segnale ECG (rumore da rete elettrica, interferenza muscolare, movimento del paziente), il malposizionamento degli elettrodi produce un tracciato che, salvo casi particolari, resta "*plausibile*": le onde sono presenti, hanno un'ampiezza e una forma ragionevoli, e nulla nell'aspetto generale del tracciato segnala immediatamente l'anomalia a un occhio poco esperto. Questo rende il problema particolarmente insidioso e, al tempo stesso, difficile da affrontare con semplici tecniche di controllo qualità del segnale.

Obiettivi della tesi

L'obiettivo di questo lavoro è lo sviluppo e la validazione di un sistema automatico in grado di rilevare il malposizionamento degli elettrodi a partire da un singolo tracciato ECG a 12 derivazioni, senza richiedere un tracciato di riferimento acquisito correttamente sullo stesso paziente. In particolare, il lavoro si pone i seguenti obiettivi specifici:

- costruire un dataset di grandi dimensioni ed etichettato in modo affidabile, a partire da database pubblici di ECG correttamente acquisiti, tramite la simulazione algebrica degli effetti di uno scambio di elettrodi sulle derivazioni standard;
- progettare un'architettura di deep learning in grado di sfruttare non solo l'informazione morfologica di ciascuna singola derivazione, ma anche la relazione *spaziale* e *temporale* che lega le diverse derivazioni tra loro;
- validare sperimentalmente il modello proposto su un insieme di test bilanciato, misurandone le prestazioni complessive e per singola tipologia di scambio, e confrontandole con approcci di riferimento più semplici;

- discutere criticamente i risultati ottenuti, i limiti dell'approccio e la sua trasferibilità a un contesto clinico reale.

Contributi della tesi

Il contributo originale di questo lavoro può essere sintetizzato in tre punti principali.

In primo luogo, viene proposta una **pipeline di simulazione degli scambi di elettrodi** basata sulle equazioni algebriche che legano le derivazioni standard ai potenziali dei singoli elettrodi (leggi di Einthoven e Goldberger, terminale centrale di Wilson). Questo approccio consente di generare, a partire da tracciati acquisiti correttamente, esempi etichettati e realistici delle principali tipologie di scambio, superando l'assenza di annotazioni di questo tipo nei database pubblici disponibili.

In secondo luogo, vengono proposte tre architetture: una ibrida *CNN+GCN*, in cui il ramo convoluzionale 1D estrae feature morfologiche da ciascuna derivazione, mentre la rete convoluzionale a grafo (*Graph Convolutional Network*) mette in relazione tali feature secondo una matrice di adiacenza costruita a partire dalla geometria spaziale reale delle derivazioni; una *CNN* pura e un *MLP*.

In terzo luogo, viene condotta una **validazione sperimentale** del modello proposto, con un'analisi dei modelli allenati sulle stesse classi di scambio, anche multi-classe, e uno studio mirato all'identificazione dei malposizionamenti sfruttando falsi positivi e falsi negativi.

Organizzazione dell'elaborato

Il resto dell'elaborato è organizzato come segue.

Il Capitolo 2 richiama le nozioni di anatomia ed elettrofisiologia cardiaca necessarie a comprendere l'origine del segnale ECG, il posizionamento

standard degli elettrodi, il calcolo delle dodici derivazioni e i criteri di normalità di un tracciato.

Il Capitolo 3 presenta una rassegna dello stato dell'arte relativo al rilevamento automatico del malposizionamento degli elettrodi, distinguendo tra metodi classici basati su regole cliniche e criteri morfologici e i più recenti approcci basati su machine learning e deep learning.

Il Capitolo 4 introduce le basi matematiche utilizzate nel resto del lavoro: le trasformate di Fourier, Laplace e Z, la teoria dei filtri lineari, e le tecniche di elaborazione del segnale ECG digitale (campionamento, quantizzazione, preprocessing e filtraggio).

Il Capitolo 5 descrive nel dettaglio la costruzione del dataset utilizzato, a partire dai database pubblici PTB-XL e Georgia, illustrando lo split per paziente, la segmentazione beat-by-beat e le equazioni utilizzate per simulare gli scambi di elettrodi.

Il Capitolo 6 descrive le architetture citate precedentemente e come avviene il *message-passing* tra le varie architetture.

Il Capitolo 7 presenta il protocollo di validazione sperimentale, le metriche utilizzate e i risultati ottenuti, complessivi e per singola classe di scambio, confrontati con le baseline di riferimento.

Il Capitolo 8 discute i risultati ottenuti, analizzando le classi di scambio da identificare, la trasferibilità clinica del sistema e i limiti legati all'utilizzo di un dataset sintetico.

Il Capitolo 9, infine, riassume i risultati raggiunti e propone possibili sviluppi futuri del lavoro di ricerca.

Capitolo 1

Elettrocardiografia e basi elettrofisiologiche

Prima di affrontare il problema del malposizionamento degli elettrodi e le tecniche automatiche per il suo rilevamento, è necessario richiamare le nozioni di base. Questo capitolo introduce in primis l'anatomia del cuore e i meccanismi elettrofisiologici alla base della sua attività, per poi descrivere come tali fenomeni si trasformano nel segnale elettrocardiografico a 12 derivazioni. Successivamente, saranno approfonditi: il posizionamento standard degli elettrodi, il calcolo delle derivazioni a partire dai potenziali misurati e i criteri con cui si valuta la normalità di un tracciato.

1.1 Anatomia ed elettrofisiologia del Cuore

Il cuore è un organo muscolare cavo situato nel mediastino, leggermente spostato a sinistra. Ha il compito di distribuire il sangue (ossigenato e non) in tutto il nostro corpo.

Il cuore è diviso in quattro camere principali: atrio destro e sinistro, ventricolo destro e sinistro; gli atri sono posti nella parte superiore e hanno il compito di raccogliere il sangue e pomparlo dentro i ventricoli, questi

ultimi sono le cavità più grandi e hanno il compito di pompare il sangue ognuno nelle proprie circolazioni: circolazione polmonare per il ventricolo destro e circolazione sistemica per il ventricolo sinistro.

Camera	Funzione	Vasi associati
Atrio destro	Raccoglie il sangue venoso sistemico	Vene cave superiore e inferiore
Ventricolo destro	Pompa il sangue verso i polmoni	Arteria polmonare
Atrio sinistro	Raccoglie il sangue ossigenato	Vene polmonari
Ventricolo sinistro	Pompa il sangue verso il corpo	Aorta




Figura 1.1: Foto del cuore con vene e arterie principali, presenti anche le valvole atrioventricolari e semilunari

In ogni punto di comunicazione all'interno del cuore sono presenti delle valvole; esse garantiscono il flusso unidirezionale del sangue impedendone il reflusso. Le valvole si distinguono in due gruppi funzionali:

- **Valvole atrioventricolari: (VA)** ancorate ai muscoli papillari del

ventricolo tramite le *corde tendinee*, che impediscono il prollasso dei lembi durante la sistole ventricolare; sono presenti due valvole di questo tipo: la *valvola tricuspide*, posta tra atrio e ventricolo destro, è composta da tre lembi, e la *valvola mitrale* (o bicuspid), posta tra atrio e ventricolo sinistro e composta da due lembi.

- **Valvole semilunari:** prive di corde tendinee, si aprono e chiudono passivamente in risposta al gradiente di pressione. Abbiamo la *valvola semilunare polmonare*, posta tra ventricolo destro e arteria polmonare, e la *valvola semilunare aortica*, posta tra ventricolo sinistro e aorta.

1.1.1 La parete cardiaca

La parete del cuore è costituita da tre strati concentrici:

- **Endocardio:** lo strato più interno, formato da tessuto endoteliale; riveste le cavità cardiache e le valvole.
- **Miocardio:** lo strato intermedio e più spesso, composto da cellule muscolari striate di tipo cardiaco (*cardiomiociti*); è responsabile della forza contrattile del cuore. Lo spessore varia a seconda della camera: è massimo nel ventricolo sinistro, che deve vincere la resistenza della circolazione sistemica.
- **Epicardio:** lo strato più esterno, costituito da mesotelio e tessuto connettivo; corrisponde al *foglietto viscerale* del pericardio sieroso.

Il cuore è poi avvolto esternamente dal **pericardio**, una sacca a doppia parete composta da:

- **Pericardio fibroso:** lo strato esterno, robusto e inestensibile, che ancora il cuore al mediastino e lo protegge da sovradistensioni.
- **Pericardio sieroso:** suddiviso a sua volta in: *Foglietto parietale* che riveste internamente il pericardio fibroso e il *Foglietto viscerale* (o epicardio) che aderisce direttamente alla parete cardiaca.

Tra i due foglietti del pericardio sieroso è presente la **cavità pericardica**, che contiene una piccola quantità di liquido sieroso ($\sim 20\text{--}50\text{ mL}$) con funzione lubrificante, riducendo l'attrito durante i movimenti del cuore.

1.1.2 Contrazione e composizione cellulare

Il cuore è composto principalmente da **cardiomiociti**, cellule muscolari striate specializzate che si contraggono involontariamente per pompare il sangue. Queste cellule sono connesse tramite i **dischi intercalari**, strutture che contengono desmosomi, utilizzati per l'ancoraggio meccanico, e **giunzioni gap**, canali che permettono il passaggio diretto di ioni tra cellule adiacenti, garantendo una propagazione rapida dell'impulso elettrico.




Figura 1.2: cardiomicito

L'impulso viene generato dalle **cellule nodali**, in gergo *pacemaker*, che a differenza dei cardiomiociti non si contraggono, ma sono specializzate nella generazione del segnale elettrico. Queste cellule sono raggruppate nell'atrio destro in prossimità della vena cava superiore, nel **nodo senoatriale (SA)**, e hanno la capacità di depolarizzarsi spontaneamente e ritmicamente, dando origine a ogni battito cardiaco. L'impulso generato viene poi irradiato in tutto il cuore tramite un sistema di conduzione composto da fibre di conduzione.




Figura 1.3: sistema di conduzione del cuore

1.1.3 Il Ciclo Cardiaco

Il ciclo cardiaco rappresenta la sequenza di eventi meccanici ed elettrici che si ripete ad ogni battito. A riposo, per un adulto medio, la frequenza cardiaca è di circa **60–80 battiti/min**, per cui ogni ciclo dura circa **800 ms**. Ogni ciclo cardiaco è formato da due azioni principali: sistole (contrazione) e diastole (rilassamento).

Prima fase

La prima fase del ciclo cardiaco è per convenzione la **sistole atriale**, che spinge il sangue dagli atri nei ventricoli. Questa fase ha una durata di circa 100 ms, alla fine della quale, inizia la **diastole atriale** che durerà fino all'inizio del prossimo ciclo cardiaco.

Seconda fase

La seconda fase è invece la **sistole ventricolare**, questa ha una durata di circa 270 ms e suddivide ulteriormente in due sotto-fasi:

- **fase isovolumetrica**: dove la pressione spinge le valvole AV a chiudersi, ma non ne crea abbastanza per aprire le valvole semilunari.
- **fase propulsiva**: la pressione aumenta e supera quella delle arterie, le valvole semilunari si aprono e il sangue viene espulso.

Terza fase

Qui avviene l'ultima fase del ciclo cardiaco, la **diastole ventricolare**; anch'essa divisa in due sotto-fasi:

- **fase precoce**: la pressione ventricolare inizia a calare, parte del sangue refluisce verso le valvole semilunari, chiudendole. Il sangue inizia a fluire negli atri rilasciati.
- **fase tardiva**: la diminuzione della pressione nei ventricoli apre le valvole AV, permettendo un riempimento passivo dei ventricoli.

1.1.4 Elettrofisiologia

Lo standard per l'elettrocardiogramma (ECG) è a dodici derivazioni, esse sono generate da 10 elettrodi posizionati sulla cute in specifici punti; prima di parlare di ECG, andiamo a vedere che cosa misuriamo effettivamente tramite gli elettrodi.

Potenziale di membrana

I cardiomiociti, come tutte le cellule muscolari, mantengono a riposo un **potenziale di membrana negativo**, pari a circa **-90 mV**; ed è proprio grazie a questo squilibrio elettrico che la cellula è in grado di contrarsi. Il potenziale negativo a riposo rappresenta infatti uno *stato di carica*, come un condensatore pronto a scaricarsi: quando arriva il segnale elettrico appropriato, la cellula può depolarizzarsi rapidamente e innescare la contrazione muscolare.




Figura 1.4: Potenziale a riposo di un cardiomiocito

Questo potenziale negativo viene mantenuto dalla naturale distribuzione asimmetrica degli ioni tra l'interno e l'esterno della cellula: gli ioni K^+ sono presenti in alta concentrazione *all'interno*, mentre gli ioni Na^+ si trovano in alta concentrazione *all'esterno*. Questa asimmetria, tuttavia, tende naturalmente a degradarsi.

Gli ioni K^+ , seguendo il loro gradiente di concentrazione, fuoriescono dalla cellula attraverso un canale passivo chiamato **Kir** (canale a rettificazione interna). Poiché ogni ione K^+ che esce porta con sé una carica positiva, l'interno della cellula diventa progressivamente più negativo contribuendo al potenziale di riposo, ma impoverendo la cellula di K^+ . Per contrastare questa perdita e mantenere stabile la distribuzione ionica, entra in gioco la **pompa Na/K-ATPasi**. Si tratta di una pompa *attiva*, che consuma energia sotto forma di ATP, che lavora *contro gradiente* trasportando simultaneamente:

- **3 ioni Na^+** verso l'esterno,
- **2 ioni K^+** verso l'interno.

In questo modo, la pompa ripristina continuamente le concentrazioni ioniche, mantenendo l'interno ricco di K^+ e l'esterno ricco di Na^+ e con esse, il potenziale di membrana negativo che rende possibile la contrazione.

Fasi della contrazione

Quando arriva lo stimolo generato dalle cellule nodali, il cardiomiocita attraversa un ciclo elettrico suddiviso in cinque fasi (da 0 a 4).

Fase 0 – Depolarizzazione rapida Lo stimolo provoca l'apertura dei canali voltaggio-dipendenti del Na^+ , una grande quantità di ioni Na^+ entra all'interno della cellula, portando cariche positive all'interno. Il potenziale di membrana passa rapidamente da -90 mV a circa $+30$ mV. Questo processo, in cui la cellula perde la sua polarità negativa interna, prende il nome di **depolarizzazione**.

Fase 1 – Ripolarizzazione iniziale I canali del Na^+ si inattivano e gli ioni K^+ iniziano a muoversi verso gradiente tramite i canali passivi **Kir**, la fuoriuscita provoca una breve e parziale ripolarizzazione della membrana.

Fase 2 – Plateau Si apre una corrente di ioni Ca^{2+} attraverso i canali di tipo L, la cui carica positiva in entrata **bilancia** la fuoriuscita di K^+ , mantenendo il potenziale di membrana su un valore pressoché stabile per circa 200 ms. Questa fase è fondamentale perché l'ingresso di Ca^{2+} permetta la contrazione del cardiomiocita.

Fase 3 – Ripolarizzazione rapida I canali del Ca^{2+} si chiudono mentre i canali del K^+ rimangono aperti: la fuoriuscita massiva di K^+ riporta il potenziale di membrana rapidamente verso i valori di riposo.

Fase 4 – Riposo Il potenziale di membrana si stabilizza a -90 mV. La pompa Na/K ripristina attivamente le concentrazioni ioniche originali, facendo uscire i Na^+ e reintroducendo K^+ . Il processo opposto alla depolarizzazione, ovvero il ripristino della polarità negativa interna, prende il nome di **ripolarizzazione**.




Figura 1.5: Onda di depolarizzazione, verso destra

La cosa fondamentale è che la propagazione dello stimolo non avviene istantaneamente su tutte le cellule, ma si propaga nel tempo tramite le *giunzioni gap*. Questa zona di confine tra la parte depolarizzata e quella ancora a riposo viene chiamata **fronte di depolarizzazione**. In corrispondenza di tale fronte si crea un **dipolo**, ed è proprio questo a generare il campo elettrico che poi si espanderà fino alla superficie del nostro corpo.

Il verso del dipolo segue il verso di propagazione del fronte.

1.2 ECG a 12 derivazioni

Gli elettrodi sono dei trasduttori e hanno il compito di misurare le differenze di potenziale sulla superficie corporea, generate dalle correnti ioniche che scorrono all'interno del sistema di conduzione del cuore.

Un elettrodo misura solamente i campi elettrici generati dall'onda di depolarizzazione, che sono diretti verso di esso, ad esempio, se rispetto all'elettrodo, il cardiomiocito è angolato di 45° , dovremmo dividere il vettore del campo in 2 parti e prendere quella nella direzione dell'elettrodo. Questo è il motivo per il quale abbiamo bisogno di relativamente tanti elettrodi in posti diversi per analizzare in modo adeguato il funzionamento del cuore.

1.2.1 Posizionamento degli elettrodi

Come spiegato precedentemente, gli elettrodi fisici che devono essere posizionati sul corpo sono dieci: **6 precordiali**, posizionati nello spazio intercostale sul piano trasversale (foto di destra), più precisamente abbiamo: *V1* sul quarto spazio intercostale linea parasternale destra, *V2* quarto spazio intercostale linea parasternale sinistra, *V3* a metà strada tra *V2* e *V4*, *V4* quinto spazio intercostale linea emiclaveare sinistra, *V5* quinto spazio intercostale linea ascellare anteriore sinistra e *V6* quinto spazio intercostale linea ascellare media sinistra, e **4 periferici**, i 2 superiori sono solitamente posizionati nella spalla o nel polso mentre i 2 inferiori nella caviglia o nella gamba (foto di sinistra).

Nel grafo dell'ECG abbiamo dodici derivazioni, di cui nove unipolari e tre bipolari:

- **V1-V6**: sono i grafi generati dai sei elettrodi precordiali, numerati dal mediastino (*V1*) alla parte laterale del corpo (*V6*).
- **aVR**: grafo proveniente dal braccio destro (polso o spalla).




Figura 1.6: Posizionamento degli elettrodi

- **aVL**: grafo proveniente dal braccio sinistro. (polso o spalla).
- **aVF**: grafo proveniente dal piede sinistro (caviglia o gamba).
- **I**: utilizza il braccio destro come polo negativo e il braccio sinistro come polo positivo.
- **II**: utilizza il braccio destro come polo negativo e il piede sinistro come polo positivo.
- **III**: utilizza il braccio sinistro come polo negativo e il piede sinistro come polo positivo.

L'elettrodo nel piede destro viene utilizzato dall'elettrocardiografo per minimizzare il rumore e ridurre le interferenze elettriche, come fosse la massa di un circuito elettrico.

1.2.2 Calcolo delle Derivazioni

Le dodici derivazioni dell'ECG non sono tutte ottenute allo stesso modo: si distinguono infatti le *derivazioni bipolari*, teorizzate da Einthoven, le *derivazioni unipolari aumentate*, teorizzate da Goldberger.

Derivazioni pericordiali

Le derivazioni $V1-V6$ utilizzano un punto di riferimento comune, a potenziale zero, chiamato *terminale centrale di Wilson*: viene calcolato come la media dei tre elettrodi periferici, escludendo il piede destro.

Derivazioni di Einthoven

Le derivazioni I , II e III costituiscono il cosiddetto **triangolo di Einthoven**: i tre elettrodi periferici (braccio destro, braccio sinistro e piede sinistro) vengono idealmente collegati tra loro a formare un triangolo equilatero, con il cuore posizionato al centro. Ogni derivazione misura la differenza di potenziale tra una coppia di elettrodi (da cui il termine *bipolare*):

- **I** = braccio sinistro (+) – braccio destro (–)
- **II** = piede sinistro (+) – braccio destro (–)
- **III** = piede sinistro (+) – braccio sinistro (–)

Dalla geometria del triangolo discende la cosiddetta **legge di Einthoven**, secondo cui la somma algebrica delle derivazioni I e III è pari alla derivazione II :

$$I + III = II$$

Questa relazione è utile anche come controllo di coerenza del tracciato registrato.

Derivazioni di Goldberger

Le derivazioni aVR , aVL e aVF sono invece *unipolari*: misurano il potenziale di un singolo elettrodo periferico rispetto a un riferimento comune, chiamato *terminale centrale*. Goldberger propose di costruire tale riferimento come media dei due elettrodi periferici diversi da quello esplorato, escludendo però quest'ultimo dal calcolo del riferimento stesso. Questo accorgimento fa sì che il segnale ottenuto risulti amplificato del 50% rispetto

a quanto si otterrebbe usando il *terminale centrale di Wilson* (media di tutti e tre gli elettrodi periferici), da cui il prefisso "a" nel nome:

- **aVR** (*augmented Vector Right*): esplora il braccio destro.
- **aVL** (*augmented Vector Left*): esplora il braccio sinistro.
- **aVF** (*augmented Vector Foot*): esplora il piede sinistro.

Le sei derivazioni periferiche (I, II, III, aVR, aVL, aVF), pur derivando dagli stessi tre elettrodi fisici, osservano il cuore secondo angolazioni diverse sul piano frontale, distanziate tra loro di 30°: è proprio questa disposizione angolare a essere riorganizzata nel sistema Cabrera descritto più avanti.




Figura 1.7: Viste prospettiche del cuore rispetto a Einthoven e Goldberger

1.2.3 Visibilità

L'ECG a 12 derivazioni consente una buona visione del cuore offrendo una copertura complessiva di tutte le pareti cardiache. Le derivazioni inferiori (II, III, aVF) esplorano la parete inferiore, le derivazioni laterali (I,

aVL, V5, V6) la parete laterale, mentre le derivazioni precordiali (V1–V4) forniscono informazioni sulla parete anteriore e sul setto interventricolare.

Ne consegue che alcune regioni risultano scarsamente rappresentate nella configurazione standard, come la parete posteriore e il ventricolo destro, che richiedono derivazioni aggiuntive per una valutazione completa.

Per questa ragione, le derivazioni di questa tipologia di ECG vengono tradizionalmente organizzate e interpretate in funzione della visione del ventricolo sinistro: ciascun gruppo di derivazioni corrisponde a una parete specifica di tale ventricolo, consentendo una lettura ordinata per regioni anatomiche. È proprio su questo principio che si fonda il sistema Cabrera, che propone una riorganizzazione delle derivazioni frontali secondo una sequenza anatomicamente continua relativamente all'angolo di osservazione del ventricolo, con l'obiettivo di rendere più intuitiva l'interpretazione dell'attività elettrica del ventricolo sinistro.




Figura 1.8: Sistema Cabrera

1.2.4 Lettura ECG

L'elettrocardiografo presenta un diagramma per ogni derivazione. La differenza di potenziale, espressa in mV , è rappresentata sull'asse Y, mentre il tempo è rappresentato sull'asse delle X. L'ECG viene stampato su carta millimetrata caratterizzata da piccoli quadrati da un mm di lato (riga fine) e grandi quadrati di $5 mm$ di lato (riga spessa); in un elettrocardiografo ben calibrato e con velocità di stampa standard a $25 mm/s$, avremo che $10 mm$ (due blocchi grandi) sull'asse Y corrispondono ad $1 mV$, e $10 mm$ sull'asse delle X equivalgono a $400 ms$. Le fasi della contrazione cardiaca si presentano nell'ECG tramite un pattern ricorrente di diverse onde: la prima, chiamata **onda P**, rappresenta la depolarizzazione atriale, l'evento elettrico che innesca e precede la contrazione meccanica (sistole) atriale, ed è solitamente visibile nella maggior parte delle derivazioni; poi abbiamo il **complesso QRS**, che rappresenta la depolarizzazione ventricolare, l'evento elettrico che precede e innesca la sistole ventricolare, ed è composto da tre deflessioni distinte: l'*onda Q* (prima deflessione negativa) data dalla depolarizzazione del setto interventricolare, l'*onda R* (deflessione positiva principale) data dalla depolarizzazione delle pareti "libere", essendo il ventricolo sinistro con massa muscolare maggiore, il suo vettore predomina, infine abbiamo l'*onda S* (seconda deflessione negativa) data dalla depolarizzazione alla base dei ventricoli, cioè nella parte alta, vicino ai grandi vasi. Il complesso QRS è di maggiore ampiezza e durata rispetto all'onda P, a indicare la maggiore massa muscolare dei ventricoli. Segue il **segmento ST**, un breve tratto isoelettrico che avviene tra la fine della depolarizzazione ventricolare e l'inizio della ripolarizzazione; in condizioni fisiologiche si trova sulla linea di base. Infine, l'**onda T** rappresenta la ripolarizzazione ventricolare, ovvero il ritorno delle cellule miocardiche allo stato di riposo in preparazione al ciclo successivo; è normalmente positiva nelle derivazioni in cui il complesso QRS presenta una deflessione principale positiva.

Ovviamente, la visibilità e la direzione delle onde non saranno le stesse per tutte le derivazioni perché, come detto in precedenza, gli elettrodi misurano

i campi elettrici direzionati verso di essi. Quindi ogni derivazione mostrerà diversi aspetti del ciclo cardiaco, ad esempio, in V1 l'onda R è minuscola e la S è profonda mentre in V5-V6 è l'opposto, l'onda R è alta e la S è quasi assente.




Figura 1.9: onda P QRS T

Tra le onde è possibile misurare alcuni **intervalli** di rilevanza clinica. L'**intervallo PR**, misurato dall'inizio dell'onda P all'inizio del complesso QRS, riflette il tempo di conduzione atrioventricolare, ovvero il ritardo fisiologico introdotto dal nodo atrioventricolare prima che l'impulso raggiunga i ventricoli; il suo valore normale è compreso tra 120 e 200 *ms*. L'**intervallo QT**, misurato dall'inizio del complesso QRS alla fine dell'onda T, rappresenta la durata complessiva della sistole elettrica ventricolare, comprensiva sia della depolarizzazione che della ripolarizzazione; poiché dipende dalla frequenza cardiaca, viene spesso corretto con apposite formule (QTc) e il suo valore normale è generalmente inferiore a 440 *ms* nell'uomo e 460 *ms* nella donna.

Ritmo sinusale normale

Viene definito **ritmo sinusale normale** un ritmo cardiaco in cui ogni impulso ha origine regolarmente dal nodo senoatriale, si propaga attraverso il sistema di conduzione in modo fisiologico e produce sull'ECG un pattern

caratteristico e ripetitivo. È importante precisare che la presenza di un ritmo sinusale normale indica esclusivamente la corretta origine e conduzione dell'impulso elettrico, non escludendo la presenza di patologie strutturali o funzionali del cuore.

I criteri che definiscono questo ritmo sono i seguenti:

- Ogni complesso QRS deve essere preceduto da un'onda P
- L'intervallo PR deve essere costante e compreso tra 120 e 200 *ms*
- La frequenza cardiaca deve essere compresa tra 60 e 100 battiti al minuto
- I complessi QRS devono essere regolarmente distanziati tra loro
- L'onda P deve essere positiva in *I* e *II*, e negativa in *aVR*

Capitolo 2

Stato dell'arte

Il rilevamento automatico del malposizionamento degli elettrodi è un problema studiato in letteratura da diversi decenni, molto prima della diffusione delle tecniche di deep learning. La maggior parte dei metodi storicamente proposti, e tuttora impiegati nella pratica clinica e nei software degli elettrocardiografi commerciali, si basa su **criteri morfologici e regole derivate dall'elettrofisiologia**, piuttosto che su modelli appresi da grandi quantità di dati. Solo recentemente, e quasi esclusivamente in ambito di ricerca, sono stati proposti approcci basati su machine learning e deep learning. Questo capitolo ripercorre entrambe le famiglie di metodi, evidenziandone vantaggi, limiti e il lavoro qui spiegato rispetto ad esse.

2.1 Metodi classici basati su regole

2.1.1 Scambi degli elettrodi periferici

Gli scambi che coinvolgono gli elettrodi periferici (braccio destro, braccio sinistro, gamba sinistra) sono la categoria di malposizionamento più studiata, poiché il loro effetto sulle derivazioni di Einthoven e di Goldberger è descrivibile in modo esatto tramite le equazioni geometriche presentate nel Capitolo 2 1.2.1. I metodi classici sfruttano proprio questa prevedi-

bilità, costruendo alberi decisionali basati sulla polarità e sull'ampiezza dell'onda P, sulla morfologia del complesso QRS e sulla relazione tra le derivazioni [31].

Un criterio storicamente molto utilizzato è quello della **polarità dell'onda P in derivazione aVR**: in condizioni di corretto posizionamento e ritmo sinusale, l'onda P è normalmente negativa in aVR; la maggior parte degli scambi tra gli elettrodi periferici che non coinvolgono l'elettrodo di terra produce invece un'onda P positiva in questa derivazione, un segnale facilmente verificabile in modo automatico [31]. In modo analogo, lo scambio tra braccio sinistro e gamba sinistra, che non altera la polarità in aVR, può essere identificato confrontando l'ampiezza dell'onda P nelle derivazioni I e II: un'ampiezza maggiore in I rispetto a II è indicativa di questo specifico scambio [31].

Un secondo filone di lavori sfrutta la **direzione di iscrizione del vettore P nel piano frontale**: in condizioni fisiologiche il ciclo descritto dal vettore P durante la depolarizzazione atriale segue, con rarissime eccezioni, un verso antiorario; un'inversione di questo verso, unita alla posizione osservata dell'asse dell'onda P, permette di classificare con buona accuratezza (secondo alcuni studi fino a oltre il 90% dei casi) quale coppia di elettrodi periferici sia stata scambiata, anche senza disporre di un tracciato di riferimento del medesimo paziente [14].

Un terzo approccio, complementare ai precedenti, si basa sulla **ridondanza informativa** intrinseca delle sei derivazioni periferiche, che sono tutte calcolabili a partire dai medesimi tre potenziali misurati agli elettrodi. Alcuni algoritmi ricostruiscono le derivazioni attese a partire da un sottoinsieme di esse e le confrontano, tramite indici di correlazione, con quelle effettivamente registrate; una discrepanza sistematica tra derivazioni ricostruite e osservate è indicativa di uno scambio [21, 22]. Un esempio di questo filone è l'analisi delle correlazioni incrociate tra le derivazioni periferiche e la derivazione V6, che si è dimostrata efficace anche in assenza di annotazioni di riferimento [18].

2.1.2 Scambi degli elettrodi precordiali

Il rilevamento degli scambi tra elettrodi precordiali (V1–V6) è generalmente considerato più complesso rispetto a quello degli elettrodi periferici, poiché non esiste per queste derivazioni un vincolo algebrico altrettanto rigido quanto la legge di Einthoven: l'informazione discriminante è quindi prevalentemente morfologica. I metodi classici sfruttano principalmente la **progressione dell'onda R** attraverso le derivazioni V1–V6, che in condizioni normali cresce in modo pressoché monotono da V1 a V5–V6, mentre l'onda S segue l'andamento opposto. Un'interruzione o un'inversione di questa progressione tra derivazioni adiacenti è un indicatore classico, sebbene non sempre specifico, di un possibile scambio o di un posizionamento verticale non corretto (ad esempio in uno spazio intercostale errato) [18].

In modo analogo a quanto visto per le derivazioni periferiche, anche per i precordiali sono stati proposti metodi basati sulla **correlazione tra derivazioni adiacenti**: la somiglianza morfologica attesa tra V1 e V2, o più in generale tra derivazioni vicine sul torace, tende ad aumentare in modo anomalo quando due elettrodi vengono scambiati tra loro, un effetto quantificabile con semplici coefficienti di similitudine [17, 18].

2.1.3 Limiti dei metodi classici

I metodi basati su regole presentano il vantaggio di essere interpretabili, computazionalmente leggeri e, in molti casi, già integrati nel software degli elettrocardiografi commerciali. Tuttavia, essi condividono alcuni limiti strutturali: le soglie e le regole utilizzate sono spesso calibrate su popolazioni o dataset specifici e generalizzano male in presenza di ritmi non sinusali, di alterazioni patologiche della morfologia dell'onda P o del complesso QRS, o di rumore significativo sul tracciato [5]; inoltre, la loro accuratezza varia molto a seconda della specifica coppia di elettrodi scambiati, risultando generalmente più bassa per gli scambi precordiali e per gli scambi periferici che coinvolgono l'elettrodo di terra, per i quali l'effetto sul tracciato è meno marcato [22, 5]. Già a metà degli anni '90 questi

limiti avevano motivato i primi tentativi di sostituire, almeno in parte, le regole scritte a mano con modelli appresi dai dati, ad esempio tramite reti neurali artificiali applicate al riconoscimento degli scambi periferici [13].

2.2 Approcci basati su apprendimento automatico e deep learning

Negli ultimi anni, un numero sempre più grande di lavori ha affrontato il problema del rilevamento del malposizionamento con un approccio mirato alla classificazione supervisionata, affidandosi a tecniche di apprendimento automatico piuttosto che a regole scritte manualmente. È importante sottolineare che, ad oggi, questi approcci restano in larga parte confinati alla ricerca accademica [34]: nella pratica clinica corrente il controllo del corretto posizionamento degli elettrodi si basa quasi esclusivamente sui criteri a regole descritti nella sezione precedente, o sulla verifica visiva da parte del personale sanitario.

Un primo filone di lavori utilizza algoritmi di **machine learning tradizionale** (support vector machine, alberi decisionali, k-nearest neighbor) applicati a feature estratte manualmente dal tracciato, quali ampiezze e durate delle onde, indici di correlazione tra derivazioni e parametri morfologici del complesso QRS [11]. Studi di questo tipo, focalizzati in particolare sul rilevamento dello scambio delle derivazioni precordiali V1 e V2, riportano accuratezze nell'ordine dell'85–95% a seconda dello spazio intercostale coinvolto e dell'algoritmo di selezione delle feature utilizzato. [33].

Un secondo filone, più recente, applica tecniche di **deep learning** direttamente al segnale grezzo, senza una fase esplicita di estrazione manuale delle feature. Le architetture proposte in letteratura sono in prevalenza reti convoluzionali monodimensionali (CNN 1D), talvolta alleggerite per essere eseguibili su dispositivi con risorse computazionali limitate [15], addestrate a distinguere il tracciato correttamente posizionato da diverse tipologie di scambio simulato, sia sulle derivazioni periferiche sia su quelle precor-

diali [35, 15, 2]. Questi lavori riportano, in generale, prestazioni superiori rispetto ai corrispondenti metodi basati su feature manuali, a fronte però di una minore interpretabilità del modello e di una forte dipendenza dalla qualità e dalla rappresentatività del dataset di addestramento [2], un aspetto particolarmente rilevante dato che, come nel presente lavoro, tali dataset sono quasi sempre costruiti simulando artificialmente gli scambi a partire da tracciati correttamente acquisiti.

Un aspetto comune alla gran parte dei lavori esistenti, sia classici sia basati su deep learning, è che le diverse derivazioni vengono tipicamente trattate come segnali indipendenti, o al più confrontate a coppie tramite indici di correlazione, senza modellare esplicitamente la struttura spaziale complessiva del sistema delle dodici derivazioni. Ad oggi, l'impiego di architetture a grafo per rappresentare esplicitamente la geometria spaziale delle derivazioni ECG in questo specifico compito non risulta ampiamente esplorato in letteratura; è proprio in questo spazio che si colloca il contributo originale proposto nel Capitolo 6 di questa tesi, dove la relazione spaziale tra derivazioni viene resa esplicita al modello tramite una matrice di adiacenza costruita sulla geometria reale del sistema di acquisizione, anziché essere lasciata implicita o appresa indirettamente dai dati; viengono oltretutto esplorate un'architettura CNN monodimensionale e un MLP, in modo da poter esplorare tutte le strade plausibili nel campo del deep learning.

2.3 Posizionamento del presente lavoro

Alla luce di quanto discusso, il presente lavoro si colloca all'intersezione tra i due filoni descritti: da un lato adotta un'architettura di deep learning, coerentemente con la tendenza più recente della letteratura; dall'altro cerca di superare il limite comune alla maggior parte dei modelli esistenti, ovvero il trattamento sostanzialmente indipendente delle singole derivazioni, incorporando esplicitamente nell'architettura l'informazione geometrica relativa alla disposizione spaziale degli elettrodi. I dettagli della pipeline

di simulazione degli scambi e dell'architettura proposta sono presentati rispettivamente nei Capitoli 4 e 5.

Capitolo 3

Basi matematiche ed elaborazione del segnale

3.1 Fondamenta matematiche

Prima di affrontare le tecniche di elaborazione del segnale ECG è necessario introdurre gli strumenti matematici su cui esse si fondano. Questa sezione presenta le trasformate fondamentali per l'analisi dei segnali, la teoria dei filtri lineari e il concetto di funzione di trasferimento, che costituiranno il riferimento teorico per tutte le sezioni successive [28, 27].

3.1.1 Fondamenti matematici per l'analisi dei segnali

Il segnale ECG come oggetto matematico

Il segnale ECG nel mondo fisico è un segnale **continuo nel tempo**, formalmente una funzione:

$$x : \mathbb{R} \rightarrow \mathbb{R}, \quad t \mapsto x(t)$$

dove t è il tempo in secondi e $x(t)$ è la differenza di potenziale in millivolt misurata tra due elettrodi. Presenta una struttura morfologica ripetitiva,

corrispondente al ciclo PQRST ma non è strettamente periodico, poiché la durata di ogni ciclo varia leggermente nel tempo. Tale variabilità, nota come *Heart Rate Variability* (HRV), costituisce una fonte di informazione clinicamente rilevante e sarà trattata nella sezione dedicata all'analisi nel dominio del tempo.

la funzione $x(t)$ appartiene allo spazio $L^2(\mathbb{R})$, ovvero è una funzione a **energia finita**:

$$E = \int_{-\infty}^{+\infty} |x(t)|^2 dt < \infty$$

Questa proprietà è fondamentale: garantisce l'esistenza della trasformata di Fourier e la validità di tutte le operazioni di filtraggio che verranno trattate nelle sezioni successive.

Trasformata di Laplace

La trasformata di Laplace è lo strumento fondamentale per l'analisi dei sistemi lineari **a tempo continuo** [28]. Data una funzione $x(t) : \mathbb{R} \rightarrow \mathbb{R}$ causale (ovvero nulla per $t < 0$), la sua trasformata di Laplace unilaterale è definita come:

$$X(s) = \mathcal{L}\{x(t)\} = \int_0^{+\infty} x(t) e^{-st} dt$$

dove $s = \sigma + j\omega \in \mathbb{C}$ è la variabile complessa, con $\sigma \in \mathbb{R}$ parte reale e $\omega \in \mathbb{R}$ parte immaginaria. L'integrale converge nella **regione di convergenza** (ROC), ovvero l'insieme dei valori di s per cui l'integrale esiste finito.

La trasformata inversa di Laplace è data dall'integrale di Bromwich:

$$x(t) = \mathcal{L}^{-1}\{X(s)\} = \frac{1}{2\pi j} \int_{\sigma-j\infty}^{\sigma+j\infty} X(s) e^{st} ds$$

In pratica, l'antitrasformata viene quasi sempre calcolata tramite scomposizione in frazioni parziali e utilizzo di tavole delle trasformate note, evitando il calcolo diretto dell'integrale.

Proprietà fondamentali. Le proprietà della trasformata di Laplace che risultano più utili nell'analisi dei sistemi sono le seguenti. La **linearità** garantisce che:

$$\mathcal{L}\{\alpha x(t) + \beta y(t)\} = \alpha X(s) + \beta Y(s)$$

La proprietà di **derivazione** trasforma la derivata nel dominio del tempo in una moltiplicazione nel dominio di s :

$$\mathcal{L}\left\{\frac{d^n x}{dt^n}\right\} = s^n X(s) - \sum_{k=0}^{n-1} s^{n-1-k} x^{(k)}(0^-)$$

che per condizioni iniziali nulle si riduce a $s^n X(s)$. Questa proprietà è alla base della descrizione dei sistemi dinamici: un'equazione differenziale nel dominio del tempo diventa un'equazione algebrica nel dominio di s , molto più semplice da trattare.

La proprietà di **convoluzione** stabilisce che:

$$\mathcal{L}\{x(t) * h(t)\} = X(s) \cdot H(s)$$

dove $*$ indica la convoluzione. L'uscita di un sistema lineare è la convoluzione dell'ingresso con la risposta impulsiva del sistema; nel dominio di s tale operazione diventa una semplice moltiplicazione, rendendo molto più agevole l'analisi dei sistemi in cascata.

Relazione con la trasformata di Fourier. La trasformata di Fourier si ottiene dalla trasformata di Laplace valutandola solamente sull'asse immaginario, ovvero ponendo $\sigma = 0$ e $s = j\omega = j2\pi f$:

$$X(j\omega) = X(s)|_{s=j\omega} = \int_{-\infty}^{+\infty} x(t) e^{-j\omega t} dt$$

Questa relazione è valida se e solo se il segnale sia strettamente *causale* (come definito in 3.1.1) e l'asse immaginario appartenga alla ROC.

Geometricamente, la trasformata di Fourier è la restrizione della trasformata di Laplace alla retta verticale $\text{Re}(s) = 0$ nel piano complesso. Mentre

la trasformata di Laplace descrive il comportamento transitorio e la stabilità di un sistema, la trasformata di Fourier ne descrive la risposta in regime sinusoidale stazionario, ovvero la risposta in frequenza.

Trasformata di Fourier

La trasformata di Fourier estende il concetto di serie di Fourier (valido per segnali periodici) ai segnali aperiodici a *energia finita* [28]. Data $x(t) \in L^2(\mathbb{R})$, la trasformata di Fourier è definita come:

$$X(f) = \mathcal{F}\{x(t)\} = \int_{-\infty}^{+\infty} x(t) e^{-j2\pi ft} dt$$

e la trasformata inversa come:

$$x(t) = \mathcal{F}^{-1}\{X(f)\} = \int_{-\infty}^{+\infty} X(f) e^{j2\pi ft} df$$

$X(f)$ è in generale una funzione a valori complessi. Il suo modulo $|X(f)|$ è detto **spettro di ampiezza** e descrive l'intensità di ciascuna componente frequenziale, mentre la sua fase $\Delta X(f)$ indica lo sfasamento di ogni componente sinusoidale. La quantità $|X(f)|^2$ è detta **densità spettrale di energia** e il teorema di Parseval garantisce la conservazione dell'energia nelle due rappresentazioni:

$$\int_{-\infty}^{+\infty} |x(t)|^2 dt = \int_{-\infty}^{+\infty} |X(f)|^2 df$$

Una proprietà fondamentale è quella di derivazione nel dominio del tempo: sia $f(t)$ continua e derivabile, siano $f(t)$ e $f'(t)$ integrabili a energia finita, allora possiamo dire che derivare una funzione nel tempo (dominio reale) equivale a moltiplicare la sua trasformata di Fourier per $j\omega$

$$\mathcal{F}\{f'(t)\} = j\omega \mathcal{F}\{f(t)\}$$

Trasformata di Fourier discreta (DFT). Per segnali disponibili come **sequenze finite** di N campioni $\{x[n]\}_{n=0}^{N-1}$, la Trasformata di Fourier

Discreta è definita come [27]:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad k = 0, 1, \dots, N-1$$

dove k indicizza le frequenze discrete $f_k = k \cdot f_s/N$. La trasformata inversa è:

$$x[n] = \frac{1}{N} \sum_{k=0}^{N-1} X[k] e^{j2\pi kn/N}, \quad n = 0, 1, \dots, N-1$$

Il calcolo diretto della DFT richiede $\mathcal{O}(N^2)$ operazioni. L'**algoritmo FFT** (*Fast Fourier Transform*) riduce questa complessità a $\mathcal{O}(N \log N)$ sfruttando la simmetria della DFT, rendendo l'analisi spettrale computazionalmente praticabile anche su segnali di lunga durata.

Trasformata Z

La trasformata Z è l'analogo discreto della trasformata di Laplace e costituisce lo strumento naturale per l'analisi e la progettazione di filtri digitali [27]. Data una sequenza discreta $x[n]$, la sua trasformata Z bilaterale è definita come:

$$X(z) = \mathcal{Z}\{x[n]\} = \sum_{n=-\infty}^{+\infty} x[n] z^{-n}, \quad z \in \mathbb{C}$$

La serie converge in un sottoinsieme del piano complesso detto **regione di convergenza** (ROC). Il termine z^{-n} ha un'interpretazione geometrica diretta: per $z = re^{j\omega}$, la trasformata Z valuta la sequenza $x[n]$ pesata da un'esponenziale complessa a frequenza ω e ampiezza r^{-n} .

Significato di z^{-1} . L'elemento fondamentale della trasformata Z è la proprietà di ritardo: moltiplicare per z^{-k} nel dominio Z corrisponde a ritardare la sequenza di k campioni nel dominio del tempo:

$$\mathcal{Z}\{x[n-k]\} = z^{-k} X(z)$$

Questa proprietà rende z^{-1} interpretabile come un **operatore di ritardo unitario**: un elemento che restituisce il campione precedente. È l'elemento

fondamentale con cui si costruiscono i filtri digitali, poiché qualsiasi equazione alle differenze con campioni ritardati si traduce immediatamente in un'espressione algebrica in z .

Relazione con la trasformata di Fourier a tempo discreto (DTFT).

Valutando la trasformata Z sulla circonferenza unitaria $|z| = 1$, ovvero ponendo $z = e^{j\omega}$, si ottiene la trasformata di Fourier a tempo discreto (DTFT):

$$X(e^{j\omega}) = X(z)|_{z=e^{j\omega}} = \sum_{n=-\infty}^{+\infty} x[n] e^{-j\omega n}$$

La DTFT è una funzione *continua* della variabile di frequenza ω (o, equivalentemente, di $f = \omega f_s / 2\pi$), definita per sequenze $x[n]$ generalmente di lunghezza infinita. Essa generalizza al caso discreto la trasformata di Fourier continua, ed esiste (in senso classico) solo per le sequenze la cui ROC della trasformata Z include la circonferenza unitaria.

Dalla DTFT alla DFT. La **DFT**, definita in precedenza per sequenze finite di N campioni, si ottiene **campionando la DTFT** in N punti equispaziati lungo la circonferenza unitaria, alle frequenze discrete:

$$\omega_k = \frac{2\pi k}{N}, \quad k = 0, 1, \dots, N-1$$

ovvero:

$$X[k] = X(e^{j\omega}) \Big|_{\omega=\frac{2\pi k}{N}} = X(e^{j2\pi k/N})$$

La DFT è dunque una sequenza **discreta** di N valori, mentre la DTFT è una funzione continua di ω , di cui la DFT ne rappresenta un campionamento in frequenza.

Proprietà fondamentali. Le proprietà più rilevanti per l'analisi dei filtri digitali sono la **linearità**:

$$\mathcal{Z}\{\alpha x[n] + \beta y[n]\} = \alpha X(z) + \beta Y(z)$$

e la proprietà di **convoluzione**, analoga a quella della trasformata di Laplace:

$$\mathcal{Z}\{x[n] * h[n]\} = X(z) \cdot H(z)$$

dove $*$ indica la convoluzione discreta. Come nel caso continuo, questa proprietà trasforma l'operazione di filtraggio, che nel dominio del tempo è una convoluzione, in una moltiplicazione nel dominio Z .

3.1.2 Spline

La spline viene utilizzata per problemi di interpolazione e nasce per superare all'utilizzo di un singolo polinomio che in presenza di molti punti diventa di grado molto alto, generando delle brusche oscillazioni nella funzione interpolante, definito come fenomeno di Runge.

Una spline di grado n su una partizione $\{t_1, \dots, t_k\}$ è una funzione $S(t)$ tale che:

- su ogni intervallo $[t_i, t_{i+1}]$ ci sia un polinomio di grado $\leq n$
- è continua insieme alle derivate fino al grado $n - 1$ nei punti di raccordo t_i

La regolarità C^{n-1} nei punti di raccordo descritta sopra rappresenta la condizione di *massima regolarità teorica* raggiungibile per una spline di grado n , e vale esclusivamente nel caso di *nodi semplici*, cioè quando ogni nodo t_i compare una sola volta nella partizione. Nel seguito, la trattazione si limiterà a questo caso. In presenza di *nodi multipli* (un nodo ripetuto con molteplicità m), la regolarità nel punto di giunzione si riduce, cioè la spline risulta continua solamente fino alla derivata di ordine $n - m$, permettendo così di introdurre in modo controllato discontinuità o spigoli nella curva o nelle sue derivate.

B-spline

Le B-spline sono molto importanti, in quanto qualsiasi funzione spline può essere scritta come combinazione lineare di B-spline [40]. Una proprietà

fondamentale di esse è il **supporto compatto minimo**: data una B-spline di grado n , allora essa sarà non nulla solamente nell'intervallo determinato da $n+2$ nodi consecutivi; al di fuori di questo intervallo la funzione assume valore zero.

Questa funzione presenta diversi vantaggi: il primo è dato dal fatto che, grazie al supporto compatto minimo, spostando un nodo, o modificando un coefficiente, la modifica si propaga solamente a un numero *limitato e ben definito* di intervalli adiacenti, cioè quelli coperti dal supporto della B-spline di grado n , ovvero $n+2$ nodi consecutivi, mentre il resto della curva, al di fuori di questa finestra, rimane invariato; il secondo nasce di conseguenza. Infatti, la B-spline risulta molto efficiente in quanto il calcolo di un punto della curva non richiede l'elaborazione di tutta la curva considerando tutti i punti, ma solamente delle B-spline il cui supporto contiene quel punto. Infine sono particolarmente indicate per i filtri FIR [40].

Definizione La B-spline di grado 0 è una semplice funzione rettangolare:

$$\beta^0(t) = \begin{cases} 1 & 0 \leq t \leq 1 \\ 0 & \text{altrimenti} \end{cases}$$

Le B-spline di grado n sono continue insieme alle loro derivate fino all'ordine $n-1$, le B-spline di ordine superiore si costruiscono per **auto-convoluzione** [40]:

$$\beta^n(t) = \underbrace{\beta^0 * \beta^0 \dots * \beta^0}_{n+1 \text{ volte}}$$

Metodi per il calcolo della convoluzione. Esistono due modi principali per calcolare un'operazione di convoluzione:

Integrale di convoluzione In generale l'operazione di convoluzione tra due funzioni $f(t)$ e $g(t)$ è:

$$(f * g)(t) = \int_{-\infty}^{+\infty} f(\alpha)g(t - \alpha) d\alpha$$

In questo caso f e g sono la stessa funzione. In termini grafici, questa operazione equivale a prendere la funzione rettangolare β^0 e scorrerla come una finestra sull'altra; è per questo motivo che β^1 è una funzione triangolare.

Trasformata di Fourier Per la proprietà di convoluzione delle trasformate, una qualsiasi operazione di convoluzione nel dominio reale diventa una semplice moltiplicazione nel dominio delle trasformate:

$$\mathcal{F}\{f * g\}(\omega) = \mathcal{F}\{f\}(\omega) \cdot \mathcal{F}\{g\}(\omega)$$

Ora calcoliamo la trasformata di β^0 :

$$\hat{\beta}^0(\omega) = \int_{-\infty}^{+\infty} \beta^0(t) \cdot e^{-j\omega t} dt = \int_0^1 e^{-j\omega t} dt = \left[\frac{e^{-j\omega t}}{-j\omega} \right]_0^1 = \frac{1 - e^{-j\omega}}{j\omega}$$

Quindi ci basterà elevare il risultato finale alla $n+1$ per ottenere una B-spline di grado n :

$$\hat{\beta}^n = \left(\frac{1 - e^{-j\omega}}{j\omega} \right)^{n+1}$$

3.1.3 Filtri lineari e funzione di trasferimento

Un **filtro digitale** è un sistema che trasforma una sequenza di ingresso $x[n]$ in una sequenza di uscita $y[n]$ secondo una relazione definita da un'equazione alle differenze. Un sistema si dice **lineare** se rispetta il principio di sovrapposizione: la risposta alla somma di due ingressi è uguale alla somma delle risposte ai singoli ingressi, ovvero per qualsiasi scalari α, β e ingressi $x_1[n], x_2[n]$ [27]:

$$T\{\alpha x_1[n] + \beta x_2[n]\} = \alpha T\{x_1[n]\} + \beta T\{x_2[n]\}$$

Un sistema si dice **tempo-invariante** se la sua risposta non dipende dall'istante temporale assoluto in cui viene applicato l'ingresso: ritardare l'ingresso di k campioni produce semplicemente un'uscita ritardata di k campioni, senza alterarne la forma. Un sistema che gode di entrambe

le proprietà è detto **LTI** (*Linear Time-Invariant*) e costituisce la classe di sistemi più ampiamente studiata nell'elaborazione dei segnali, poiché è completamente caratterizzata dalla propria **risposta impulsiva** $h[n]$, ovvero dall'uscita prodotta quando l'ingresso è un impulso unitario $\delta[n]$.

Equazione alle differenze. La forma generale di un filtro LTI causale è:

$$\sum_{k=0}^N a_k y[n-k] = \sum_{m=0}^M b_m x[n-m]$$

con $a_0 = 1$ per convenzione. I coefficienti $\{b_m\}$ pesano i campioni correnti e passati dell'ingresso (parte *feedforward*), mentre i coefficienti $\{a_k\}$ con $k \geq 1$ pesano i campioni passati dell'uscita (parte *feedback*). La presenza o assenza di quest'ultima determina la distinzione tra le due grandi famiglie di filtri digitali.

Funzione di trasferimento. Applicando la trasformata Z all'equazione alle differenze e sfruttando la proprietà di ritardo $\mathcal{Z}\{y[n-k]\} = z^{-k}Y(z)$, si ottiene:

$$Y(z) \sum_{k=0}^N a_k z^{-k} = X(z) \sum_{m=0}^M b_m z^{-m}$$

La **funzione di trasferimento** è il rapporto tra la trasformata Z dell'uscita e quella dell'ingresso a condizioni iniziali nulle:

$$H(z) = \frac{Y(z)}{X(z)} = \frac{\sum_{m=0}^M b_m z^{-m}}{\sum_{k=0}^N a_k z^{-k}}$$

$H(z)$ è una funzione razionale in z^{-1} che contiene tutta l'informazione sul comportamento del filtro. I valori di z per cui il numeratore si annulla sono detti **zeri**; i valori per cui il denominatore si annulla sono detti **poli**. La posizione di poli e zeri nel piano complesso determina completamente le proprietà del filtro.

Risposta in frequenza. Valutando $H(z)$ sulla circonferenza unitaria si ottiene la **risposta in frequenza** del filtro:

$$H(e^{j2\pi f/f_s}) = |H(f)| e^{j\Delta H(f)}$$

Il modulo $|H(f)|$ è detto **risposta in ampiezza** e descrive quanto il filtro amplifica o attenua ciascuna componente frequenziale; la fase $\Delta H(f)$ descrive il ritardo di fase introdotto. Un filtro ideale passa-basso con frequenza di taglio f_c avrebbe:

$$|H(f)| = \begin{cases} 1 & |f| \leq f_c \\ 0 & |f| > f_c \end{cases}$$

I filtri reali approssimano questo comportamento ideale con transizioni graduali tra banda passante e banda attenuata.

Impulso unitario e risposta impulsiva.

L'impulso unitario discreto, detto anche **delta di Kronecker**, è la sequenza definita come:

$$\delta[n] = \begin{cases} 1 & n = 0 \\ 0 & n \neq 0 \end{cases}$$

Esso costituisce l'elemento identità rispetto alla convoluzione discreta e gode di una proprietà fondamentale, detta **proprietà di campionamento**:

$$\sum_{k=-\infty}^{+\infty} x[k] \delta[n-k] = x[n]$$

che esprime il fatto che qualsiasi sequenza $x[n]$ può essere decomposta in una somma di impulsi traslati e pesati dai propri valori. Questa decomposizione, combinata con le proprietà di linearità e tempo-invarianza, implica che l'uscita di un sistema LTI a un ingresso arbitrario $x[n]$ è completamente determinata dalla risposta del sistema al solo impulso $\delta[n]$.

Si definisce **risposta impulsiva** $h[n]$ l'uscita di un sistema LTI quando l'ingresso è l'impulso unitario:

$$h[n] = T\{\delta[n]\}$$

dove $T\{\cdot\}$ indica l'operatore che descrive il sistema. La conoscenza di $h[n]$ è sufficiente a determinare l'uscita del sistema per qualsiasi ingresso $x[n]$, poiché per le proprietà LTI si ha:

$$y[n] = \sum_{k=-\infty}^{+\infty} x[k] h[n-k] = x[n] * h[n]$$

ovvero l'uscita è la **convoluzione discreta** dell'ingresso con la risposta impulsiva. Questo risultato, noto come **integrale di convoluzione discreto**, è il teorema centrale della teoria dei sistemi LTI: qualunque sistema lineare tempo-invariante è completamente caratterizzato dalla propria risposta impulsiva.

La funzione di trasferimento $H(z)$, introdotta nella sezione precedente come rapporto $Y(z)/X(z)$, coincide con la trasformata Z della risposta impulsiva:

$$H(z) = \frac{Y(z)}{X(z)} = \mathcal{Z}\{h[n]\}$$

Le due espressioni non sono definizioni indipendenti: la seconda segue direttamente dalla prima applicando la proprietà di convoluzione della trasformata Z all'identità $y[n] = x[n] * h[n]$.

La durata di $h[n]$ distingue le due grandi famiglie di filtri digitali. Se $h[n]$ è nulla al di fuori di un intervallo finito $[0, M]$, il filtro è detto FIR (*Finite Impulse Response*); se $h[n]$ è non nulla per infiniti valori di n , tipicamente decade asintoticamente a zero, il filtro è detto IIR (*Infinite Impulse Response*). Nel secondo caso la presenza di una componente di feedback nell'equazione alle differenze è la causa diretta della durata infinita della risposta impulsiva.

Filtri FIR e IIR.

Se tutti i coefficienti $a_k = 0$ per $k \geq 1$, allora il denominatore di $H(z)$ è costante e il filtro non ha poli (eccetto nell'origine). In questo caso l'uscita dipende solo dai campioni correnti e passati dell'ingresso, la risposta

impulsiva ha durata finita e il filtro è detto **FIR** (*Finite Impulse Response*):

$$H_{FIR}(z) = \sum_{m=0}^M b_m z^{-m}$$

I filtri FIR sono sempre stabili e possono essere progettati per avere **fase lineare**, proprietà che garantisce un ritardo costante e uguale per tutte le frequenze; condizione importante nell'analisi ECG per non distorcere la morfologia delle onde.

Se invece almeno un coefficiente $a_k \neq 0$, il filtro presenta un anello di retroazione: l'uscita attuale dipende anche dalle uscite passate. La risposta impulsiva ha durata infinita e il filtro è detto **IIR** (*Infinite Impulse Response*):

$$H_{IIR}(z) = \frac{\sum_{m=0}^M b_m z^{-m}}{\sum_{k=0}^N a_k z^{-k}}$$

I filtri IIR richiedono un numero di coefficienti inferiore rispetto ai FIR per ottenere la stessa selettività in frequenza, ma possono essere instabili se i poli si trovano fuori dalla circonferenza unitaria, e introducono in generale una fase non lineare.

Stabilità. Un filtro IIR è **BIBO stabile** (*Bounded Input Bounded Output*) ovvero produce un'uscita limitata per qualsiasi ingresso limitato, se e solo se tutti i suoi poli si trovano **all'interno della circonferenza unitaria** nel piano z :

$$|z_k| < 1 \quad \forall k = 1, \dots, N$$

I filtri FIR, non avendo poli (o avendoli solo nell'origine), sono incondizionatamente stabili.

Dalla funzione di trasferimento all'equazione alle differenze. Il percorso è sempre bidirezionale: data $H(z)$, si ricava l'equazione alle differenze moltiplicando entrambi i membri per il denominatore, espandendo

e antitrasformando termine per termine. Questo passaggio sarà utilizzato esplicitamente nella derivazione dell'algoritmo di Pan-Tompkins, dove la funzione di trasferimento del filtro passa-basso è il punto di partenza e l'equazione alle differenze ne è la diretta conseguenza implementativa.

3.2 Segnale ECG digitale

3.2.1 Campionamento e segnale discreto

Un elettrocardiografo digitale non registra $x(t)$ in modo continuo, ma ne acquisisce campioni a intervalli regolari di durata T_s secondi, detto **periodo di campionamento**. Il segnale discreto risultante è:

$$x[n] = x(nT_s), \quad n \in \mathbb{Z}$$

La **frequenza di campionamento** è $f_s = 1/T_s$, misurata in Hz. Il segnale discreto $x[n]$ è quindi una successione numerica.

Teorema di Nyquist-Shannon

Il teorema di Nyquist-Shannon stabilisce la condizione necessaria e sufficiente affinché il campionamento non introduca perdita di informazione [26, 37].

Teorema 1 (Nyquist-Shannon). *Sia $x(t) \in L^2(\mathbb{R})$ un segnale a banda limitata, ovvero tale che la sua trasformata di Fourier $X(f)$ soddisfi:*

$$X(f) = 0 \quad \forall |f| > f_{\max}$$

Allora $x(t)$ è completamente determinato dai suoi campioni $x[n] = x(n/f_s)$ se e solo se:

$$f_s > 2 f_{\max}$$

La frequenza $f_N = f_s/2$ è detta **frequenza di Nyquist**. Se questa condizione non è rispettata, componenti ad alta frequenza si sovrappongono a componenti a bassa frequenza nel segnale campionato, questo fenomeno è chiamato **aliasing** e porta alla creazione di distorsioni irrecuperabili in fase di ricostruzione.

Applicazione all'ECG. Il contenuto spettrale di un segnale ECG clinicamente rilevante si distribuisce approssimativamente nell'intervallo $[0.05, 150]$ Hz, come riportato in tabella 3.1 [4, 20].

Componente	Banda (Hz)
Baseline wander	0.05 – 0.5
Onde P e T	0.5 – 10
Complesso QRS	5 – 40
Alta frequenza	fino a 150

Tabella 3.1: Bande di frequenza delle principali componenti del segnale ECG [4].

Per rispettare il teorema di Nyquist sulla componente più rapida (150 Hz), la frequenza di campionamento minima teorica sarebbe $f_s > 300$ Hz. Nella pratica clinica si utilizzano $f_s = 500$ Hz oppure $f_s = 1000$ Hz (500 nel nostro caso), con un margine di sicurezza che tiene conto anche della necessità di ricostruire accuratamente la morfologia del QRS [20]. Prima del campionamento, un **filtro anti-aliasing** (passa-basso analogico con frequenza di taglio $\leq f_N$) viene sempre applicato al segnale continuo per eliminare le componenti che violerebbero il teorema.

Quantizzazione

Oltre al campionamento temporale, il convertitore analogico-digitale (ADC) dell'elettrocardiografo introduce una **quantizzazione** in ampiezza: il valore continuo $x(nT_s) \in \mathbb{R}$ viene approssimato al più vicino livello discreto tra i 2^B disponibili, dove B è il numero di bit del convertitore.

La **risoluzione in ampiezza** (o LSB, *Least Significant Bit*) è:

$$\Delta = \frac{V_{\max} - V_{\min}}{2^B}$$

Un ECG clinico tipico utilizza $B = 12$ oppure $B = 16$ bit [20]. Con $B = 12$ e un range dinamico di ± 5 mV si ottiene:

$$\Delta = \frac{10 \text{ mV}}{2^{12}} = \frac{10}{4096} \approx 2.4 \mu\text{V}$$

ampiamente sufficiente a risolvere tutte le componenti diagnosticamente rilevanti. L'errore introdotto dalla quantizzazione è modellato come **rumore di quantizzazione**, uniformemente distribuito nell'intervallo $[-\Delta/2, +\Delta/2]$, con potenza:

$$\sigma_q^2 = \frac{\Delta^2}{12}$$

3.2.2 Preprocessing e filtraggio

Prima di estrarre qualsiasi informazione clinicamente rilevante da un segnale ECG, è necessario pulirlo dal rumore. Un segnale ottenuto da un elettrocardiografo reale non è mai il segnale fisiologico puro: è sempre la sovrapposizione di quest'ultimo con diverse sorgenti di disturbo, alcune di origine biologica, altre di origine strumentale o ambientale [38]. Il preprocessing ha lo scopo di attenuare tali disturbi portando il segnale in condizioni adatte all'analisi successiva, senza alterarne le componenti diagnosticamente rilevanti.

Modello del rumore

Il segnale acquisito $\tilde{x}[n]$ può essere modellato come la sovrapposizione del segnale ECG ideale $x[n]$ e di tre componenti di disturbo principali:

$$\tilde{x}[n] = x[n] + \eta_{BW}[n] + \eta_{PL}[n] + \eta_{EM}[n]$$

dove $\eta_{BW}[n]$ è il baseline wander, $\eta_{PL}[n]$ è l'interferenza di rete e $\eta_{EM}[n]$ è il rumore elettromiografico. Ciascuna componente occupa una banda di frequenza distinta, il che rende possibile progettare filtri selettivi che le attenuino separatamente senza danneggiare il segnale ECG [38].

Baseline wander Il baseline wander è una lenta deriva della linea di base del segnale, tipicamente causata dal movimento degli elettrodi sulla

cute, dalla respirazione (che modifica l'impedenza toracica) e dalla sudorazione. Occupa la banda di frequenza $[0.05, 0.5]$ Hz, ben al di sotto della banda del complesso QRS, e si manifesta come un'oscillazione lenta che sposta verticalmente il tracciato ECG, rendendo difficile la misurazione precisa del segmento ST e degli intervalli.

Interferenza di rete L'interferenza di rete (*powerline interference*) è causata dal campo elettromagnetico generato dalla rete elettrica domestica. Si presenta come una sinusoide a frequenza fissa di 50 Hz in Europa, eventualmente con le sue armoniche. Pur essendo a frequenza fissa, cade parzialmente nella banda del QRS (5–40 Hz) e pertanto non può essere eliminata con un semplice passa-basso.

Rumore elettromiografico Il rumore elettromiografico (EMG) è generato dall'attività elettrica dei muscoli scheletrici circostanti durante il movimento del paziente. Occupa una banda ampia, tipicamente $[20, 500]$ Hz, e si sovrappone alle componenti ad alta frequenza del QRS. È la componente più difficile da eliminare perché condivide parzialmente la banda del segnale di interesse [38].

Rimozione del baseline wander

Poiché il baseline wander occupa frequenze molto basse rispetto al contenuto del segnale ECG, la sua rimozione si ottiene applicando un **filtro passa-alto** con frequenza di taglio $f_c \approx 0.5$ Hz. Tuttavia, un filtro IIR del primo ordine con $f_c = 0.5$ Hz introduce una risposta transitoria molto lenta, proporzionale a $1/f_c$, che può richiedere diversi secondi per stabilizzarsi all'inizio della registrazione. Per questo motivo si preferisce spesso un approccio alternativo basato sulla stima della linea di base.

Stima e sottrazione della linea di base. L'idea è stimare $\eta_{BW}[n]$ applicando al segnale grezzo $\tilde{x}[n]$ una **media mobile** su una finestra

sufficientemente lunga da catturare solo le variazioni lente, e poi sottrarla:

$$\hat{\eta}_{BW}[n] = \frac{1}{W_{BW}} \sum_{k=0}^{W_{BW}-1} \tilde{x}[n-k]$$

$$x_{hp}[n] = \tilde{x}[n] - \hat{\eta}_{BW}[n]$$

La finestra W_{BW} deve essere più lunga del periodo del QRS (circa 200 ms) per non distorcerlo; in pratica si utilizzano finestre di 600–1000 ms, corrispondenti a 300–500 campioni con $f_s = 500$ Hz.

Un approccio più robusto, consigliato dalle linee guida AHA, è la doppia applicazione di un filtro mediano: prima con una finestra di 200 ms (per rimuovere il complesso QRS dalla stima della baseline), poi con una finestra di 600 ms (per lisciare la stima risultante) [38].

Rimozione dell'interferenza di rete

L'interferenza di rete a frequenza fissa si rimuove con un **filtro notch**, un filtro che attenua selettivamente una singola frequenza lasciando inalterate tutte le altre. La funzione di trasferimento di un filtro notch nel dominio Z presenta una coppia di zeri sulla circonferenza unitaria alla frequenza f_0 e una coppia di poli appena all'interno della circonferenza unitaria alla stessa frequenza, per garantire la stabilità:

$$H_{notch}(z) = \frac{1 - 2 \cos(2\pi f_0/f_s) z^{-1} + z^{-2}}{1 - 2r \cos(2\pi f_0/f_s) z^{-1} + r^2 z^{-2}}$$

dove $r \in (0, 1)$ è il raggio dei poli, che controlla la larghezza della banda attenuata: valori di r prossimi a 1 producono una banda molto stretta (filtro selettivo), valori più piccoli allargano la banda di attenuazione. In pratica si utilizzano valori $r \approx 0.95$ – 0.99 . Con $f_0 = 50$ Hz e $f_s = 500$ Hz:

$$\omega_0 = 2\pi \cdot \frac{50}{500} \approx 0.628 \text{ rad/campione}$$

Filtraggio passa-banda

Dopo la rimozione del baseline wander e dell'interferenza di rete, si applica un **filtro passa-banda** che seleziona la banda del segnale ECG diagnosticamente rilevante, tipicamente $[0.5, 40]$ Hz, attenuando le componenti

residue fuori banda. Questo filtro è la versione più accurata e raffinata del filtro passa-banda approssimato usato nell'algoritmo di Pan-Tompkins; mentre quest'ultimo è ottimizzato per la velocità computazionale, il filtro qui descritto è progettato per massimizzare la qualità del segnale.

Filtro di Butterworth. Il filtro di Butterworth è un filtro IIR caratterizzato da una risposta in ampiezza **massimamente piatta** nella banda passante, ovvero priva di ondulazioni (*ripple*) [6]. La risposta in ampiezza al quadrato di un filtro passa-basso di Butterworth di ordine N con frequenza di taglio Ω_c è:

$$|H(j\Omega)|^2 = \frac{1}{1 + (\Omega/\Omega_c)^{2N}}$$

All'aumentare di N , la transizione tra banda passante e banda attenuata diventa più ripida, avvicinandosi al comportamento ideale. Per un'applicazione ECG tipica, un filtro di Butterworth di ordine $N = 4-6$ rappresenta un buon compromesso tra selettività e distorsione di fase.

La progettazione avviene nel dominio continuo tramite trasformata di Laplace, e il filtro viene poi discretizzato tramite la **trasformazione bilineare**, che mappa il piano s nel piano z , secondo:

$$s = \frac{2}{T_s} \cdot \frac{1 - z^{-1}}{1 + z^{-1}}$$

garantendo che un filtro stabile nel dominio continuo rimanga stabile nel dominio discreto [27]. La trasformazione bilineare introduce una distorsione non lineare dell'asse delle frequenze (*warping*), che viene compensata pre-distorcendo opportunamente le frequenze di taglio del progetto analogico.

Filtro FIR a fase lineare. Un'alternativa agli IIR è il filtro FIR progettato con il **metodo di Parks-McClellan**, che minimizza il massimo errore di approssimazione in banda passante e attenuata (*equiripple*) [30].

La funzione di trasferimento è:

$$H_{FIR}(z) = \sum_{m=0}^M b_m z^{-m}$$

Il vantaggio principale rispetto ai filtri IIR è la **fase lineare**: il ritardo introdotto è identico per tutte le frequenze, preservando la morfologia delle onde ECG senza distorcerne la forma. Lo svantaggio è la maggiore lunghezza del filtro: per ottenere la stessa selettività di un Butterworth di ordine 4, un FIR richiede tipicamente $M = 50\text{--}200$ coefficienti.

Pipeline di preprocessing completa

Le operazioni descritte nelle sezioni precedenti vengono applicate in sequenza, formando una **pipeline** di preprocessing. L'ordine delle operazioni non è arbitrario: rimuovere prima il baseline wander facilita la stima della soglia nel filtro notch; applicare il passa-banda per ultimo garantisce che nessuna componente di rumore introdotta dai filtri precedenti sopravviva all'uscita. La pipeline standard è quindi:

1. Rimozione del baseline wander (filtro mediano o passa-alto)
2. Rimozione dell'interferenza di rete (filtro notch o LMS)
3. Filtraggio passa-banda $[0.5, 40]$ Hz

Il segnale risultante $x_{clean}[n]$ è la stima del segnale ECG ideale $x[n]$ su cui verranno eseguite tutte le analisi successive. È importante sottolineare che il preprocessing introduce inevitabilmente un **ritardo di gruppo**. Per i filtri FIR a fase lineare questo ritardo è costante e pari a $M/2$ campioni, facilmente compensabile; per i filtri IIR il ritardo dipende dalla frequenza e non è compensabile in modo esatto. Nelle applicazioni in cui la localizzazione temporale precisa dei picchi è critica, come nel rilevamento del QRS, il ritardo di gruppo deve essere tenuto in considerazione e, quando possibile, corretto.

Capitolo 4

Dataset e simulazione degli scambi

Questo capitolo descrive il processo con cui è stato costruito il dataset utilizzato per l'addestramento, la validazione e il test del modello di deep learning presentato in questa tesi. I punti di partenza sono due database pubblici distribuiti da PhysioNet [8], **PTB-XL** [41] e **Georgia** [32], da cui sono stati estratti i tracciati ECG grezzi. A partire da questi, il dataset finale è stato ottenuto tramite un'unica pipeline che elabora e combina entrambe le sorgenti. Organizzata in tre fasi logicamente distinte:

1. la **suddivisione delle registrazioni** di ciascun database in insiemi di training, validazione e test, effettuata separatamente su PTB-XL e Georgia e poi unita, in modo da garantire che nessun paziente sia condiviso tra split diversi;
2. la **segmentazione beat-by-beat** delle registrazioni, con lo scopo di isolare singoli battiti cardiaci in finestre temporali di dimensione fissa; il numero di battiti estratti per registrazione dipende dallo split di appartenenza;
3. la **simulazione artificiale di scambi di elettrodi**, necessaria

per generare esempi etichettati di posizionamento errato, dato che nessuno dei due database originali contiene annotazioni di questo tipo.

Nei paragrafi seguenti vengono presentate le caratteristiche dei due database di partenza, motivate le scelte progettuali di ciascuna fase e descritta nel dettaglio la struttura del dataset finale. Un terzo database, utilizzato esclusivamente per una valutazione indipendente del modello, è presentato separatamente nella Sezione ??.

4.1 Database di partenza

4.1.1 Il database PTB-XL

PTB-XL è un database pubblico di ECG clinici a 12 derivazioni, pubblicato dal Physikalisch-Technische Bundesanstalt (PTB) e reso disponibile attraverso PhysioNet [41]. Si tratta, ad oggi, di uno dei più grandi database ECG annotati liberamente accessibili, per questo motivo è ampiamente utilizzato come benchmark in letteratura per problemi di classificazione automatica di segnali cardiaci o patologie.

Ogni registrazione contenuta in PTB-XL è un ECG a riposo della durata di 10 secondi, acquisito con le 12 derivazioni standard (I, II, III, aVR, aVL, aVF, V1–V6). Il database mette a disposizione i segnali grezzi a due diverse frequenze di campionamento (100 Hz e 500 Hz), oltre a un insieme di metadati per ciascuna registrazione: dati demografici del paziente (età, sesso), diagnosi codificate secondo lo standard SCP-ECG, informazioni sulla qualità del segnale e sull'apparecchiatura di acquisizione, e un identificativo di `patient_id` che collega più registrazioni allo stesso paziente, dove presenti.

Le caratteristiche principali del database sono riassunte nella Tabella 4.1.

Dal punto di vista pratico, il database è organizzato in due componenti principali:

Tabella 4.1: Caratteristiche principali del database PTB-XL [41].

Caratteristica	Valore
Numero di registrazioni ECG	21 837
Numero di pazienti	18 885
Durata di ciascuna registrazione	10 secondi
Derivazioni	12
Frequenze di campionamento disponibili	100 Hz e 500 Hz
Formato dei segnali grezzi	WFDB
Risoluzione	16 bit, 1 μ V/LSB
Annotazioni diagnostiche	Codici SCP-ECG
Metadati demografici	Età, sesso
Origine geografica	Germania (interferenza a 50 Hz)

- una cartella contenente i segnali grezzi in formato WFDB, suddivisi in sottocartelle per intervalli di `ecg_id`, disponibili sia a 100 Hz (`records100/`) sia a 500 Hz (`records500/`); in questo lavoro sono stati utilizzati esclusivamente i segnali a 500 Hz.
- un file di metadati `ptbx1_database.csv`, in cui ogni riga corrisponde a una registrazione e riporta, tra le altre cose, il percorso relativo ai file del segnale, l'identificativo del paziente e le diagnosi codificate.

Ai fini di questo lavoro, il database è stato utilizzato esclusivamente come sorgente di tracciati ECG, conassunti come correttamente acquisiti in assenza di annotazioni cliniche esplicite di malposizionamento, pur riconoscendo i limiti intrinseci legati alla potenziale presenza di rumore o errori sistematici latenti nelle registrazioni del mondo reale. Le diagnosi cliniche associate a ciascuna registrazione non sono state impiegate, poiché l'obiettivo del modello non è la diagnosi della patologia cardiaca, ma la verifica della corretta acquisizione del segnale stesso.

4.1.2 Il database Georgia

Il secondo database utilizzato è il *Georgia 12-Lead ECG Challenge Database*, distribuito da PhysioNet e originariamente pubblicato come parte dei dati di training della PhysioNet/Computing in Cardiology Challenge 2020 [32]. A differenza di PTB-XL, che rappresenta prevalentemente una popolazione europea, Georgia raccoglie registrazioni acquisite negli Stati Uniti sud-orientali, ampliando così la variabilità demografica e strumentale del dataset finale.

Ogni registrazione è un ECG a 12 derivazioni standard, campionato a 500 Hz, distribuito in formato WFDB (coppia di file `.hea/.mat`). A differenza di PTB-XL, il database non fornisce un file di metadati tabellare separato: le informazioni su ciascuna registrazione (età, sesso, diagnosi codificate secondo SNOMED-CT) sono riportate direttamente nell'header `.hea` del singolo record, e ogni registrazione corrisponde a un paziente distinto (non esistono, cioè, più registrazioni associate allo stesso `patient_id`, a differenza di PTB-XL). Le caratteristiche principali sono riassunte nella Tabella 4.2.

Tabella 4.2: Caratteristiche principali del database Georgia [32].

Caratteristica	Valore
Numero di registrazioni ECG	~10 300
Numero di pazienti	uno per registrazione
Durata di ciascuna registrazione	5 o 10 secondi
Derivazioni	12
Frequenza di campionamento	500 Hz
Formato dei segnali grezzi	WFDB
Annotazioni diagnostiche	Codici SNOMED-CT
Origine geografica	Stati Uniti (interferenza a 60 Hz)

Poiché il database non è distribuito con un unico indice tabellare, l'elenco

delle registrazioni disponibili è stato ricostruito a partire dai file **RECORDS** presenti nelle varie sottocartelle del database, ciascuno dei quali elenca i nomi dei record contenuti al suo interno; i percorsi così ottenuti sono stati utilizzati per ricavare l'insieme completo e univoco delle registrazioni disponibili.

Come per PTB-XL, anche per Georgia sono stati utilizzati esclusivamente i tracciati grezzi, applicando le stesse assunzioni.

Osservazione sull'ordine delle derivazioni e sul filtro di rete

I due database, pur condividendo lo stesso insieme di 12 derivazioni standard, differiscono in due aspetti tecnici rilevanti per l'elaborazione:

- l'ordine con cui le derivazioni sono salvate nei file WFDB è verificato esplicitamente in fase di caricamento, per evitare di associare per errore un canale alla derivazione sbagliata;
- poiché PTB-XL è stato acquisito in un contesto con interferenza della linea elettrica a 50 Hz (Europa) e Georgia con un'interferenza di 60 Hz (Stati Uniti), il filtro *notch* applicato in fase di pulizia del segnale (Sezione 3.2.2) utilizza una frequenza di taglio diversa per le due sorgenti, così da rimuovere correttamente l'interferenza di rete in entrambi i casi.

4.2 Pipeline di costruzione del dataset

La costruzione del dataset finale è realizzata da due script che elaborano PTB-XL e Georgia, in modo da ottenere con il primo script un dataset composto da segmenti beat-by-beat e preprocessati, mentre con il secondo applica le trasformazioni richieste dall'utente. Concettualmente, la pipeline è organizzata in tre fasi sequenziali:

1. **Suddivisione in train/val/test:** le registrazioni di ciascun database vengono assegnate a uno dei tre split (descritto in dettaglio nella

Sezione 4.3), in modo che tutte le registrazioni di uno stesso paziente ricadano nello stesso insieme.

2. **Segmentazione beat-by-beat:** per ogni registrazione vengono individuati i picchi R e vengono estratte finestre temporali di durata fissa centrate su di essi, secondo criteri che dipendono dallo split di appartenenza (Sezione 4.4): due battiti per registrazione in train/val, tutti i battiti validi in test.
3. **Simulazione degli scambi di elettrodi:** ai battiti di train e validazione viene assegnata un'etichetta, scelta tra "normale" e un insieme di scambi di elettrodi clinicamente plausibili, e i segnali vengono trasformati in modo coerente con l'etichetta assegnata (Sezione 4.5); i battiti di test restano invece invariati, etichettati come "normale".

Questa suddivisione in due script permette di velocizzare il processo di creazione di dataset differenti (con trasformazioni diverse), in quanto le prime due fasi, comprese nel primo script, sono sempre uguali indifferentemente dal tipo di trasformazione che si vuole applicare al dataset.

4.3 Suddivisione in training, validazione e test

La suddivisione in train/validation/test è il primo passo della costruzione del dataset, ed è pensata per evitare qualunque forma di *data leakage* tra split diversi.

La suddivisione avviene a livello di **paziente** e non di singola registrazione o singolo battito: per *PTB-XL*, dove uno stesso paziente può essere associato a più registrazioni (`ecg_id` diversi), lo split è effettuato sull'insieme dei `patient_id` univoci, così che tutte le registrazioni di uno stesso paziente vengono assegnate allo stesso split; per *Georgia*, dove ogni registrazione corrisponde a un paziente distinto, lo split sull'identificativo di registrazione è equivalente, per costruzione, a uno split per paziente.

4.3.1 Proporzioni e procedura

Per ciascun database, gli identificativi vengono ordinati, mescolati con un generatore pseudo-casuale a seed fisso e suddivisi secondo le proporzioni: 80% training, 10% validazione, 10% test, modificabili in caso di necessità dall'utente.

La suddivisione viene effettuata **separatamente** su PTB-XL e su Georgia, e successivamente i due risultati vengono uniti per formare gli split combinati finali; ogni split conterrà quindi una parte di registrazioni PTB-XL e una parte di registrazioni Georgia, nelle stesse proporzioni 80/10/10 calcolate all'interno di ciascun database. L'uso di un seed fisso rende la suddivisione riproducibile.

4.4 Segmentazione beat-by-beat

La scelta di lavorare a livello di singolo battito, anziché sull'intera registrazione, è motivata da diverse considerazioni.

Dimensione di input uniforme. Il numero di battiti contenuti in una registrazione di durata fissa dipende dalla frequenza cardiaca del soggetto, che varia da paziente a paziente e nel tempo. Segmentare rispetto al singolo battito, anziché all'intera registrazione, permette di ottenere input di dimensione fissa e nota a priori, indipendente dalla frequenza cardiaca, semplificando l'architettura della rete e il relativo addestramento.

Aumento della numerosità campionaria (train/val). Da ogni registrazione di training o validazione vengono estratti due segmenti, aumentando la numerosità del dataset a disposizione del modello, fattore particolarmente rilevante con architetture di deep learning.

Localizzazione del segnale informativo. L'obiettivo del modello è riconoscere pattern morfologici legati al posizionamento degli elettrodi, come inversioni di polarità di alcune derivazioni o scambi di ampiez-

za tra derivazioni, che sono osservabili già a livello del singolo ciclo cardiaco. Non è quindi necessario fornire al modello l'intera registrazione per permettergli di apprendere pattern più complessi non utili in questo caso di studio; concentrare l'input sul singolo battito riduce la quantità di informazione ridondante che il modello deve elaborare.

Riduzione del costo computazionale. Input più corti riducono il numero di parametri e le risorse di calcolo richieste, sia in fase di addestramento sia in fase di inferenza.

4.4.1 Rilevamento dei picchi R

Per individuare i battiti all'interno di ciascuna registrazione, è necessario innanzitutto localizzare i picchi R, cioè i picchi di ampiezza massima del complesso QRS, che costituiscono il punto di riferimento temporale più affidabile e riproducibile del ciclo cardiaco. Il rilevamento è stato eseguito tramite l'algoritmo di *Pan-Tompkins* [29].

Un aspetto progettuale rilevante riguarda la scelta della derivazione sulla quale eseguire il rilevamento. Sebbene il segnale a 12 derivazioni contenga, per ciascuna derivazione, una propria rappresentazione dello stesso ciclo cardiaco, il rilevamento dei picchi R non è stato effettuato in modo indipendente su ciascuna derivazione, ma su due *derivazioni guida*, *V1* e *V5*, scelte perché tra loro elettricamente ortogonali e con una buona visione del complesso QRS.

L'algoritmo di Pan-Tompkins viene applicato separatamente a *V1* e *V5*, ottenendo due liste di picchi candidati. Le due liste vengono poi accoppiate: per ogni picco rilevato su *V1* si cerca, su *V5*, il picco più vicino entro una tolleranza fissata (50 ms); se un accoppiamento valido viene trovato, la posizione finale del picco R è ottenuta come media delle due posizioni accoppiate, altrimenti il candidato viene scartato. Questo accoppiamento, rispetto a una semplice media indipendente delle due liste, ha lo scopo di scartare rilevamenti isolati presenti su una sola delle due derivazioni guida, ad esempio dovuti a rumore residuo, e di garantire che il picco R utilizzato

per la segmentazione sia effettivamente supportato da entrambe le derivazioni di riferimento. La medesima posizione temporale, così ottenuta, viene infine utilizzata per estrarre la finestra su tutte e dodici le derivazioni.

Questa scelta non è solo una semplificazione implementativa, ma è funzionale all'obiettivo della tesi: se il rilevamento dei picchi fosse eseguito derivazione per derivazione, uno scambio di elettrodi che alteri la morfologia di una specifica derivazione potrebbe causare un rilevamento del picco R leggermente disallineato rispetto alle altre derivazioni, introducendo nella finestra estratta un disallineamento temporale artificiale, dovuto al preprocessing e non alla reale anomalia di acquisizione. Questo problema rischierebbe di essere appreso dal modello come indicatore di misplacement, invalidando così l'esperimento.

4.4.2 Estrazione della finestra

Per ogni picco R rilevato, viene estratta una finestra temporale $[R - 400 \text{ ms}, R + 600 \text{ ms}]$, per una durata complessiva di un secondo, sincronizzata su tutte le 12 derivazioni. La Figura 4.1 illustra graficamente questa finestra su un battito di esempio.

La scelta di un'asimmetria tra la porzione precedente e quella successiva al picco R (400 ms prima, 600 ms dopo) è motivata dalla successione temporale delle componenti morfologiche dell'onda ECG all'interno di un singolo ciclo cardiaco:

- i 400 ms che precedono il picco R sono sufficienti a includere l'onda P (depolarizzazione atriale) e il tratto PR, che hanno una durata tipica complessiva dell'ordine di circa 200 ms;
- i 600 ms successivi al picco R sono necessari a includere il resto del complesso QRS, il tratto ST e l'intera onda T (ripolarizzazione ventricolare), la cui durata complessiva, specialmente considerando l'intervallo QT, può arrivare fino a circa 400–450 ms in condizio-



Figura 4.1: Finestra di segmentazione $[R - 400 \text{ ms}, R + 600 \text{ ms}]$ centrata sul picco R, sovrapposta a un tracciato ECG di esempio.

ni fisiologiche normali, con un margine di sicurezza per frequenze cardiache più basse (a cui corrisponde un intervallo QT più lungo).

Una finestra di un secondo, centrata in modo asimmetrico sul picco R, permette, nella grande maggioranza dei casi, di catturare un intero ciclo cardiaco (onda P, complesso QRS, onda T) senza includere porzioni significative del battito precedente o successivo, anche per frequenze cardiache elevate. Una finestra i cui estremi cadono fuori dai limiti della registrazione (tipicamente il primo o l'ultimo battito) viene scartata.

4.4.3 Numero di battiti estratti: differenza tra **train/val** e **test**

Il numero di battiti estratti da ciascuna registrazione dipende dallo split di appartenenza, poiché training/validazione e test hanno scopi diversi nella pipeline:

- **Training e validazione:** da ogni registrazione vengono estratti esattamente **due battiti**: i primi e gli ultimi battiti di ciascuna

registrazione di 10 secondi vengono deliberatamente evitati per eliminare l'influenza dei transitori di accensione, dei filtri analogici e degli effetti di bordo temporali introdotti dai filtri di preprocessing. La scelta del terzo e del quinto picco garantisce l'estrazione di cicli cardiaci stabili e interni alla registrazione tramite una procedura deterministica e riproducibile. Se una registrazione produce meno di cinque picchi R validi, essa viene scartata e registrata come tale (si veda la Sezione 4.6). Questi due battiti sono poi la base su cui viene applicata la simulazione degli scambi di elettrodi (Sezione 4.5).

- **Test:** da ogni registrazione vengono estratti **tutti i battiti validi**, senza limitarsi a due. Questa scelta è funzionale alla strategia di valutazione adottata, poiché, in fase di test, ogni registrazione viene classificata tramite *majority voting* sulle predizioni ottenute sui singoli battiti che la compongono, e disporre di più battiti per registrazione rende questa stima più robusta. I battiti di test non vengono sottoposti ad alcuna trasformazione e sono etichettati come “normale”, poiché rappresentano registrazioni reali presumibilmente acquisite con un posizionamento corretto degli elettrodi.

4.5 Simulazione degli scambi di elettrodi

4.5.1 Perché è necessaria una simulazione

I database di partenza, come la generalità dei database ECG pubblici, contengono esclusivamente registrazioni acquisite con un posizionamento corretto degli elettrodi: non esiste, nella pratica clinica, la produzione sistematica e su larga scala di registrazioni etichettate come “mal posizionate”, poiché si tratta di un errore di acquisizione che, quando osservato, viene generalmente corretto immediatamente e non salvato. Per addestrare un modello supervisionato in grado di riconoscere queste condizioni, è quindi necessario disporre di esempi delle diverse classi di errore, e l'unica strada percorribile è la generazione artificiale di tali esempi a partire da registra-

zioni corrette. Questa simulazione viene applicata unicamente ai battiti di training e validazione (si veda la Sezione 4.4.3); i battiti di test restano non trasformati.

Questo approccio è reso possibile dal fatto che il posizionamento errato di un elettrodo non introduce, dal punto di vista del segnale, un errore arbitrario, bensì un effetto ben determinabile e prevedibile, descrivibile a partire dalle equazioni che definiscono le derivazioni standard. È proprio questa proprietà che viene sfruttata per costruire la simulazione.

4.5.2 Equazioni delle derivazioni standard

Le sei derivazioni degli arti non sono misurate direttamente, ma calcolate a partire dai potenziali elettrici rilevati da tre elettrodi posizionati sugli arti: braccio destro (RA , right arm), braccio sinistro (LA , left arm) e gamba sinistra (LL , left leg). Indicando con V_{RA} , V_{LA} , V_{LL} i potenziali rilevati ai tre elettrodi, le tre derivazioni bipolari di Einthoven sono definite come:

$$I = V_{LA} - V_{RA} \quad (4.1)$$

$$II = V_{LL} - V_{RA} \quad (4.2)$$

$$III = V_{LL} - V_{LA} \quad (4.3)$$

mentre le tre derivazioni aumentate unipolari di Goldberger sono definite come:

$$aVR = V_{RA} - \frac{V_{LA} + V_{LL}}{2} = -\frac{I + II}{2} \quad (4.4)$$

$$aVL = V_{LA} - \frac{V_{RA} + V_{LL}}{2} = \frac{I - III}{2} \quad (4.5)$$

$$aVF = V_{LL} - \frac{V_{RA} + V_{LA}}{2} = \frac{II + III}{2} \quad (4.6)$$

Le sei derivazioni precordiali $V_1, \dots, V_6$ sono invece derivazioni unipolari riferite al *terminale centrale di Wilson* (WCT), definito come la media dei tre potenziali degli arti:

$$WCT = \frac{V_{RA} + V_{LA} + V_{LL}}{3} \quad (4.7)$$

4.5.3 Effetto di uno scambio di elettrodi

Si consideri il caso in cui i cavi collegati agli elettrodi RA e LA vengano scambiati fisicamente. Il canale che l'elettrocardiografo ha registrato come "RA" riceve, in realtà, il potenziale dell'elettrodo posizionato sul braccio sinistro, e viceversa. Sostituendo $V_{RA} \rightarrow V_{LA}$ e $V_{LA} \rightarrow V_{RA}$ nelle equazioni precedenti, si ottiene un nuovo insieme di derivazioni, indicate con l'apice:

$$I' = V_{RA} - V_{LA} = -(V_{LA} - V_{RA}) = -I \quad (4.8)$$

$$II' = V_{LL} - V_{LA} = III \quad (4.9)$$

$$III' = V_{LL} - V_{RA} = II \quad (4.10)$$

$$aVR' = V_{LA} - \frac{V_{RA} + V_{LL}}{2} = aVL \quad (4.11)$$

$$aVL' = V_{RA} - \frac{V_{LA} + V_{LL}}{2} = aVR \quad (4.12)$$

$$aVF' = V_{LL} - \frac{V_{RA} + V_{LA}}{2} = aVF \quad (4.13)$$

Le nuove derivazioni non sono altro che permutazioni delle derivazioni originali. In altre parole, è possibile ottenere il tracciato che si sarebbe osservato in caso di scambio RA-LA a partire da un tracciato acquisito correttamente, applicando esclusivamente operazioni algebriche lineari alle derivazioni già disponibili, senza dover disporre dei potenziali grezzi ai singoli elettrodi (che né PTB-XL né Georgia, come la generalità degli apparecchi clinici, forniscono). È esattamente questa proprietà che rende possibile, e corretta dal punto di vista elettrofisiologico, la simulazione degli scambi di elettrodi a partire dai soli dati disponibili.

Un'osservazione analoga si applica al terminale centrale di Wilson: poiché WCT è una somma simmetrica dei tre potenziali agli arti, il suo valore non cambia se due di questi vengono scambiati tra loro:

$$WCT' = \frac{V_{LA} + V_{RA} + V_{LL}}{3} = \frac{V_{RA} + V_{LA} + V_{LL}}{3} = WCT \quad (4.14)$$

Ne consegue che le derivazioni precordiali V_1 – V_6 non sono alterate da alcuno scambio tra gli elettrodi degli arti.

Applicando lo stesso procedimento agli altri due scambi possibili tra elettrodi degli arti (LA–LL e RA–LL), si ottengono le trasformazioni riportate in Tabella 4.3.

Tabella 4.3: Trasformazioni delle derivazioni degli arti in funzione dello scambio di elettrodi simulato. Le derivazioni precordiali (V_1 – V_6) restano invariate in tutti i casi.

Scambio	I'	II'	III'	aVR'	aVL'	aVF'
RA – LA	$-I$	III	II	aVL	aVR	aVF
LA – LL	II	I	$-III$	aVR	aVF	aVL
RA – LL	$-III$	$-II$	$-I$	aVF	aVL	aVR

Un caso ulteriore, più semplice, è lo scambio tra due cavi precordiali adiacenti, frequente nella pratica clinica per la vicinanza fisica degli elettrodi sul torace. In questo caso, poiché il terminale centrale di Wilson dipende esclusivamente dagli elettrodi degli arti e non dagli elettrodi precordiali, lo scambio si traduce semplicemente nello scambio diretto dei due canali coinvolti, lasciando invariate tutte le altre derivazioni. Il modulo di trasformazione implementa, in questa forma, tutti e cinque gli scambi tra derivazioni precordiali adiacenti (V_1 – V_2 , V_2 – V_3 , V_3 – V_4 , V_4 – V_5 , V_5 – V_6), oltre ai tre scambi tra elettrodi degli arti (RA–LA, LA–LL, RA–LL) e alla classe “normale” (nessuna trasformazione), per un totale di nove trasfor-

mazioni disponibili, riassunte in Tabella 4.4. Ciascuna classe potrà essere associata ad un peso configurabile in fase di generazione del dataset.

Tabella 4.4: Trasformazioni disponibili nel modulo di simulazione degli scambi di elettrodi.

Nome	Tipo di scambio
normal	nessuno (identità)
RA_LA	elettrodi degli arti, braccio destro / braccio sinistro
LA_LL	elettrodi degli arti, braccio sinistro / gamba sinistra
RA_LL	elettrodi degli arti, braccio destro / gamba sinistra
V1_V2	precordiale adiacente
V2_V3	precordiale adiacente
V3_V4	precordiale adiacente
V4_V5	precordiale adiacente
V5_V6	precordiale adiacente

Va inoltre osservato che lo scambio tra l'elettrodo di massa/riferimento (RL , right leg) e l'elettrodo LL non è incluso tra le trasformazioni implementate, poiché, essendo in punti anatomicamente distanti dal cuore e *isopotenziali*, i tracciati subirebbero alterazioni quasi impercettibili. Un altro motivo risiede nell'impossibilità di ricavare matematicamente il potenziale grezzo dell'elettrodo RL .

La Figura 4.2 mostra, a titolo esemplificativo, l'effetto della trasformazione RA–LA su un singolo battito segmentato, per un sottoinsieme delle derivazioni coinvolte: si osservi in particolare l'inversione di polarità della derivazione I e lo scambio di forma d'onda tra le derivazioni aVR e aVL.




Figura 4.2: Battito trasformato secondo lo scambio RA–LA.

4.5.4 Regole di generazione del dataset finale

L'applicazione pratica delle trasformazioni descritte sopra ai battiti segmentati segue alcune regole progettuali, motivate dalla necessità di produrre un dataset privo di possibili fonti di *data leakage*. Tali regole si applicano ai soli split di training e validazione, gli unici in cui viene simulato il malposizionamento (si veda la Sezione 4.4.3 per il test).

1. **I due battiti di ogni registrazione hanno etichette diverse.** Per ciascuna registrazione di training o validazione vengono estratti due segmenti, come descritto nella Sezione 4.4, e a ciascuno dei due viene assegnata un'etichetta diversa dall'altro, scelta tra “normale” e le diverse tipologie di scambio selezionate, secondo proporzioni configurabili. Questa scelta è motivata dal fatto che assegnare la stessa etichetta a entrambi i battiti di una stessa registrazione non aggiungerebbe reale informazione che la rete possa apprendere, finendo per appesantire la fase di training senza alcun guadagno.
2. **Per ciascun battito viene mantenuta una sola versione.** Il dataset finale non contiene, per uno stesso segmento originale, sia la versione acquisita correttamente sia quella trasformata: viene conservata esclusivamente la versione corrispondente alla classe assegnata. In questo modo si evita di introdurre nel dataset coppie di esempi quasi identici (differenti unicamente per l'etichetta), che comprometterebbero la validità dello split e potrebbero facilitare un apprendimento per memorizzazione anziché per generalizzazione.
3. **L'assegnazione delle classi avviene sull'insieme combinato PTB-XL + Georgia di ciascuno split.** Le etichette non vengono assegnate separatamente ai battiti dei due database, ma sull'unione di tutte le registrazioni PTB-XL e Georgia appartenenti allo stesso split (training o validazione): questo garantisce che le proporzioni tra classi richieste in fase di configurazione (ad esempio 50% “normale” e il resto suddiviso equamente tra i quattro tipi di scambio) valgano sul dataset combinato effettivamente usato per addestrare il modello,

e non separatamente sulle due sorgenti.

4. **Lo split tra training, validazione e test è definito a monte, per paziente.** Come descritto nella Sezione 4.3, la suddivisione avviene prima della segmentazione ed è basata sull'identificativo di paziente: questo garantisce che tutti i battiti provenienti da uno stesso paziente appartengano a un unico insieme, evitando che il modello venga valutato su battiti provenienti da un paziente già osservato, seppur in forma diversa, durante l'addestramento.

4.6 Struttura del dataset finale

Al termine della pipeline, il dataset è organizzato in tre sottocartelle separate, una per ciascuno split (`train/`, `val/`, `test/`), ciascuna con la stessa struttura interna:

- una cartella `segments/`, contenente un file `.npy` per ciascun battito, con forma `(12, lunghezza_finestra)`, cioè *leads-first*, con le 12 derivazioni sulla prima dimensione, dove `lunghezza_finestra` dipende dalla frequenza di campionamento scelta (500 campioni per una finestra di un secondo a 500 Hz).
- un file di indice: `final_dataset_index.csv` per gli split di training e validazione, `beats_index.csv` per lo split di test. In entrambi i casi, ogni riga corrisponde a un battito e riporta: il nome del file `.npy` corrispondente (`filename`); l'identificativo della registrazione di provenienza, prefissato con la sorgente (`ecg_id`, ad es. `ptbxl_1234` o `georgia_E00001`); l'identificativo del paziente, anch'esso prefissato con la sorgente (`patient_id`); il database di origine (`source`, `ptbxl` oppure `georgia`); la posizione del battito all'interno della registrazione (`beat_idx_in_record`); il campione in cui è stato rilevato il picco R utilizzato per la segmentazione (`r_peak_sample`); e l'etichetta di classe (`label`: `normal` oppure il tipo di scambio simulato – per il test, sempre `normal`);

- un file `skipped_records.csv`, che elenca le registrazioni scartate durante l'elaborazione di quello split, con il relativo motivo (ad esempio segnale contenente valori non definiti, numero di picchi R insufficiente, o errori di lettura/formato del file WFDB).

Questa struttura, oltre a facilitare il caricamento efficiente dei dati durante l'addestramento (ogni esempio può essere letto individualmente, senza necessità di caricare l'intero dataset in memoria), consente di ricostruire in ogni momento la provenienza di ciascun esempio, e mantiene traccia delle registrazioni escluse dalla pipeline, utile in fase di verifica della qualità del dataset. La distinzione tra i due file di indice (`final_dataset_index.csv` e `beats_index.csv`) riflette inoltre la diversa natura dei due split: mentre train e validazione sono pensati per l'addestramento a livello di singolo battito, il test è organizzato per essere valutato a livello di intera registrazione tramite *majority voting* su tutti i suoi battiti, aggregati tramite la colonna `ecg_id`.

4.7 Terzo database solo per il test

Oltre allo split di test ricavato da PTB-XL e Georgia (Sezione 4.4.3), le prestazioni del modello sono state valutate anche su un *terzo database, indipendente e utilizzato esclusivamente per il test*, con l'obiettivo di verificare la capacità di generalizzazione su registrazioni provenienti da un contesto di acquisizione completamente diverso da quello visto in fase di addestramento (diversa popolazione, apparecchiatura e origine geografica).

Il database in questione, indicato nella repository del progetto come *China database*, corrisponde all'*ECG Arrhythmia Database* distribuita da PhysioNet [42], nota in letteratura anche come database Chapman-Shaoxing-Ningbo (CSN) [43]. Si tratta di un database di ECG a 12 derivazioni raccolto in Cina, la cui popolazione, apparecchiatura di acquisizione e condizioni di registrazione differiscono sensibilmente da quelle di PTB-XL e Georgia.

4.7.1 Preparazione dei dati

Il database originale contiene 45 152 registrazioni ECG. Durante la fase di preparazione, ogni registrazione è stata convertita in un insieme di segmenti con la stessa procedura di segmentazione descritta nella Sezione 4.4 per lo split di test di PTB-XL e Georgia..

Delle 45 152 registrazioni originali, 43 712 sono state elaborate con successo, mentre 1 440 sono state escluse a causa dell'assenza di picchi R rilevabili, di segmenti validi ai bordi del segnale, oppure di errori durante il caricamento o il preprocessing (le stesse categorie di scarto già introdotte per PTB-XL e Georgia nella Sezione 4.6). Dalle registrazioni utilizzabili sono stati estratti complessivamente 445 520 battiti. Le caratteristiche principali del database e i risultati della fase di preparazione sono riassunti nella Tabella 4.5.

Tabella 4.5: Caratteristiche principali del database utilizzato esclusivamente per il test (China) [42, 43].

Caratteristica	Valore
Numero di registrazioni ECG originali	45 152
Registrazioni elaborate con successo	43 712
Registrazioni escluse	1 440
Battiti estratti	445 520
Durata di ciascuna registrazione	10 secondi
Derivazioni	12
Frequenza di campionamento	500 Hz
Formato dei segnali grezzi	WFDB
Annotazioni diagnostiche	Codici SNOMED-CT
Origine geografica	Cina (interferenza a 50 Hz)
Ruolo nella pipeline	solo test, nessuna trasformazione simulata

4.7.2 Utilizzo nella valutazione

A differenza degli split di training e validazione, sui battiti estratti dal database China non è stata applicata alcuna trasformazione artificiale di malposizionamento, tutti i battiti sono etichettati come **normal**, coerentemente con l'assunzione, già discussa per PTB-XL e Georgia, che le registrazioni pubbliche disponibili siano state acquisite con un posizionamento corretto degli elettrodi.

Questa scelta consente di misurare sul database China, la capacità di generalizzare su un contesto di acquisizione mai osservato durante il training. Come per lo split di test di PTB-XL e Georgia, anche in questo caso la valutazione non è condotta a livello del singolo battito, ma le predizioni relative ai diversi segmenti appartenenti alla stessa registrazione vengono aggregate tramite *majority voting*, ottenendo una predizione finale a livello di intera registrazione. Questa aggregazione riduce l'influenza di eventuali errori su singoli battiti isolati e permette di dare una migliore valutazione della capacità del modello di riconoscere la eventuali malposizionamenti.

Capitolo 5

Architetture proposte

Lo stato dell'arte per la classificazione di varie patologie è l'utilizzo di algoritmi di deep learning [10, 12]; in questo capitolo tratteremo le tre architetture implementate nel presente lavoro di tesi: un *Multi-Layer Perceptron* (MLP), una *Convolutional Neural Network* (CNN) monodimensionale e una *Graph Convolutional Network* (GCN) con backbone convoluzionale. Le tre architetture vengono presentate in ordine di complessità crescente, sia dal punto di vista strutturale sia da quello delle formulazioni matematiche necessarie alla loro comprensione. Per ognuna, gli iperparametri specifici (numero di layer, numero di neuroni/filtri, dimensione dei kernel, ecc.) sono stati determinati tramite ottimizzazione bayesiana con *Optuna* [1], ripetuta separatamente per ciascuna configurazione del problema (tipo di inversione e numero di classi).

5.1 Multi-Layer Perceptron

Il *Multi-Layer Perceptron* (MLP) rappresenta l'architettura più semplice tra quelle proposte ed è stato utilizzato come modello di baseline. Si tratta di una rete neurale *feed-forward* completamente connessa (*fully connected*), in cui ogni neurone di un layer riceve in ingresso l'output di tutti i neuroni del layer precedente. La rete è organizzata in dodici layer di ingresso, uno

o più layer nascosti e un layer di uscita, la cui dimensione dipende dal numero di classi del problema di classificazione affrontato.

5.1.1 Funzioni di Attivazione

Le **funzioni di attivazione** introducono non-linearità nella rete, permettendo al modello di apprendere relazioni complesse tra i dati in input. Senza di esse, indipendentemente dal numero di layer, la rete si comporterebbe come un semplice modello lineare.

Le funzioni di attivazione più comuni sono:

- **ReLU (Rectified Linear Unit)**: definita come $f(x) = \max(0, x)$, azzerava tutti i valori negativi e lascia invariati quelli positivi. È la funzione più utilizzata grazie alla sua semplicità computazionale e alla sua efficacia nel ridurre il problema del *vanishing gradient*.
- **Sigmoid**: definita come $f(x) = \frac{1}{1+e^{-x}}$, mappa i valori in un intervallo $(0, 1)$. Viene tipicamente usata nell'ultimo layer per problemi di classificazione binaria.
- **Softmax**: estensione della sigmoid per problemi multi-classe, produce una distribuzione di probabilità sull'insieme delle classi: $f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$.

5.1.2 Funzione di Loss

La *loss function* (funzione di costo) quantifica l'errore tra le previsioni del modello $\hat{y}$ e i valori reali y nel training set. L'obiettivo dell'apprendimento è minimizzare questa funzione.

Le loss function più utilizzate sono:

- **Cross-Entropy Loss** (per classificazione multi-classe): misura la distanza tra la distribuzione predetta e quella reale.

$$\mathcal{L} = - \sum_{c=1}^C y_c \log(\hat{y}_c)$$

dove C è il numero di classi, $y_c \in \{0, 1\}$ è il label reale e $\hat{y}_c$ è la probabilità predetta per la classe c .

- **Mean Squared Error** (per regressione):

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

5.1.3 Fondamenta matematiche

In questa sezione richiameremo alcuni strumenti di calcolo differenziale, necessari per la comprensione dell'aggiornamento dei pesi di una rete tramite l'algoritmo di *backpropagation*:

Chain Rule

La chain rule è la formula fondamentale per il calcolo della derivata di una funzione composta. Siano $g : \mathbb{R} \rightarrow \mathbb{R}$ e $f : \mathbb{R} \rightarrow \mathbb{R}$ derivabili, allora $g \circ f : \mathbb{R} \rightarrow \mathbb{R}$ è anch'essa derivabile, e se poniamo $h(x) = g(f(x))$, abbiamo che:

$$\frac{dh}{dx} = g'(f(x)) \cdot f'(x)$$

Espandendo il ragionamento, definiamo $q : \mathbb{R} \rightarrow \mathbb{R}$; allora $q \circ g \circ f : \mathbb{R} \rightarrow \mathbb{R}$ è derivabile, e ridefinendo $h(x) = q(g(f(x)))$ otteniamo:

$$\frac{dh}{dx} = q'(g(f(x))) \cdot g'(f(x)) \cdot f'(x)$$

Chain rule per funzioni di funzioni

Consideriamo un vettore $x(t) = (x_1(t), x_2(t), \dots, x_n(t))^T \in \mathbb{R}^n$, le cui componenti sono n funzioni derivabili. Sia inoltre $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una funzione differenziabile in $x(t)$.

Sotto queste ipotesi, la funzione composta $F(t) = f(x(t))$ risulta differenziabile in t , e la sua derivata si esprime attraverso la chain rule come:

$$F'(t) = \sum_{i=1}^n \frac{\partial f(x(t))}{\partial x_i} \cdot x'_i(t) = \langle \nabla f(x(t)), x'(t) \rangle$$

dove l'espressione finale denota il prodotto scalare tra il gradiente della funzione f e il vettore derivato $x'(t)$.

A titolo di esempio, data una funzione che dipende da due componenti generiche, ovvero $f(h(t), g(t))$, la derivata totale di f rispetto al parametro t si calcola come:

$$\frac{df}{dt} = \frac{\partial f}{\partial h} \frac{dh}{dt} + \frac{\partial f}{\partial g} \frac{dg}{dt}$$

Gradiente

Sia $A \subseteq \mathbb{R}^2$ aperto e $f : A \rightarrow \mathbb{R}$, se tutte le derivate parziali esistono e sono continue allora f è differenziabile. Se f è differenziabile allora le sue derivate parziali, (due in questo caso) in un punto P arbitrario, formano un vettore chiamato gradiente:

$$\nabla f(x_0, y_0) = \left[\frac{\partial f}{\partial x}(x_0, y_0), \quad \frac{\partial f}{\partial y}(x_0, y_0) \right]$$

Derivata direzionale

Sia $A \subseteq \mathbb{R}^2$ aperto e $f : A \rightarrow \mathbb{R}$ continua, definiamo la derivata direzionale D_v come la variazione della funzione f lungo la direzione di un **versore** v a partire da un punto P arbitrario; viene formalmente indicata come:

$$D_v f(x_0, y_0) = \lim_{t \rightarrow 0} \frac{f(x_0 + t v_x, y_0 + t v_y) - f(x_0, y_0)}{t}$$

Se f è anche **differenziabile**, allora possiamo ricorrere al **Teorema del Gradiente** per calcolare la derivata direzionale:

$$D_v f(x_0, y_0) = \nabla f(x_0, y_0) \cdot v$$

Espandendo otteniamo:

$$\left[\frac{\partial f}{\partial x}(x_0, y_0), \quad \frac{\partial f}{\partial y}(x_0, y_0) \right] \cdot \begin{pmatrix} v_x \\ v_y \end{pmatrix}$$

Ora vogliamo calcolare qual'è la direzione v in cui f ha crescita massima:

$$D_v f(x_0, y_0) = \|\nabla f(x_0, y_0)\| \cdot \|v\| \cdot \cos(\alpha)$$

dove α indica l'angolo tra il versore e il gradiente. Osservando che $\|v\| = 1$ e $-1 \leq \cos(\alpha) \leq 1$ possiamo dire che $D_v f(x_0, y_0)$ assume valore **massimo** quando $\cos(\alpha) = 1 \rightarrow \alpha = 0$, cioè se v ha stessa direzione e verso del gradiente; viceversa assume valore **minimo** quando $\cos(\alpha) = -1 \rightarrow \alpha = \pi$, cioè quando v ha stessa direzione ma verso opposto al gradiente.

5.1.4 Algoritmo di Backpropagation

Uno dei primi algoritmi proposti per il calcolo dei pesi in una rete neurale è il metodo iterativo noto come metodo di backpropagation. La riscoperta di questo metodo verso la metà degli anni '80 da parte di Rumelhart, Hinton e Williams [36] ha reso possibile definire algoritmi di addestramento per reti di grandi dimensioni, ed è stato quindi alla base del successivo sviluppo sulle reti neurali. L'algoritmo utilizza essenzialmente la tecnica utilizzata per il calcolo delle derivate della funzione di errore, basata sulle regole di derivazione delle funzioni composte.

Percorso generale di esecuzione

Prima di tutto, è necessario definire come *epoca* il compimento di una fase di training, cioè quando tutto il dataset di training è passato attraverso la rete. Il dataset di training viene suddiviso in piccoli *batch* (dimensione 16, 32, 64 ecc.), per ognuno si procede con il calcolo della funzione di loss $L(y, \hat{y})$, per poi proseguire con il calcolo della funzione di costo:

$$C(w) = \frac{1}{n_T} \sum_{j=1}^{n_T} L(y^{(j)}, \hat{y}^{(j)}(w))$$

dove n_T rappresenta la dimensione del batch di training, e $y^{(j)}, \hat{y}^{(j)}$ sono rispettivamente le etichette e le predizioni della rete al j -esimo esempio di training. Infine dobbiamo aggiornare i pesi muovendoci in direzione dell'antigradiente per cercare di minimizzare la funzione di costo:

$$w^{(k)} = w^{(k-1)} - \eta \nabla C(w)$$

dove η rappresenta il **learning rate** (tasso di apprendimento) che definisce di quanto dobbiamo muoverci verso la direzione dell'antigradiente; questo parametro è fondamentale per l'apprendimento delle reti, in quanto, con valori troppo piccoli, la convergenza della rete richiederebbe tempi troppo lunghi, quindi più energia consumata e più epoche, mentre valori troppo grandi potrebbero evitare che la rete converga, in quanto i punti di minimo che cerchiamo di ottenere potrebbero essere "saltati" direttamente.




Figura 5.1: Differenza nella scelta del learning rate

5.1.5 Calcolo del Gradiente in un MLP

L'obiettivo della backpropagation è calcolare le derivate parziali della funzione di loss L rispetto a ciascun peso della rete, così da poterli aggiornare tramite la discesa del gradiente. In un MLP, ogni neurone i del layer ℓ riceve in ingresso una combinazione lineare degli output del layer precedente:

$$a_i^{(\ell)} = \sum_j w_{ji}^{(\ell)} z_j^{(\ell-1)} + b_i^{(\ell)}$$

e produce in uscita il valore attivato:

$$z_i^{(\ell)} = f(a_i^{(\ell)})$$

dove f è la funzione di attivazione e $z_j^{(\ell-1)}$ è l'output del j -esimo neurone del layer precedente.

Gradiente rispetto ai pesi

Applicando la chain rule, la derivata parziale della loss rispetto al peso $w_{ji}^{(\ell)}$ che connette il neurone j del layer $\ell - 1$ al neurone i del layer ℓ è:

$$\frac{\partial L}{\partial w_{ji}^{(\ell)}} = \frac{\partial L}{\partial a_i^{(\ell)}} \cdot \frac{\partial a_i^{(\ell)}}{\partial w_{ji}^{(\ell)}} = \delta_i^{(\ell)} \cdot z_j^{(\ell-1)}$$

dove abbiamo definito il **segnale di errore** δ del neurone i al layer ℓ come:

$$\delta_i^{(\ell)} = \frac{\partial L}{\partial a_i^{(\ell)}}$$

Il gradiente rispetto a un peso è quindi il semplice prodotto tra il delta del neurone di destinazione e l'output del neurone sorgente.

Calcolo del segnale di errore

Il calcolo di $\delta_i^{(\ell)}$ dipende dalla posizione del neurone nella rete.

Layer di uscita. Se il neurone i , con $i = 1, \dots, k$, appartiene al layer di uscita L , il delta si calcola direttamente derivando la loss rispetto alla preattivazione tramite la chain rule:

$$\delta_i^{(L)} = \frac{\partial L(\hat{y}_i)}{\partial a_i^{(L)}} = f'(a_i^{(L)}) \frac{\partial L(\hat{y}_i)}{\partial \hat{y}_i}$$

Il primo fattore è la derivata della funzione di attivazione valutata nella preattivazione, il secondo è la derivata della loss rispetto all'output predetto $\hat{y}_i = z_i^{(L)}$.

Layer nascosto. Se il neurone i , con $i = 1, \dots, k$, appartiene a un layer nascosto ℓ , il suo output $z_i^{(\ell)}$ contribuisce alla preattivazione di *tutti* i neuroni del layer successivo. Applicando la chain rule su tutti questi percorsi:

$$\delta_i^{(\ell)} = \frac{\partial L}{\partial a_i^{(\ell)}} = f'(a_i^{(\ell)}) \sum_{k=0}^{N^{(\ell+1)}} \delta_k^{(\ell+1)} w_{ik}^{(\ell+1)}$$

dove $N^{(\ell)}$ è il numero di neuroni nel layer ℓ e la somma accumula i contributi di errore provenienti da tutti i neuroni del layer successivo, pesati dai rispettivi pesi. Questa formula permette di **propagare il segnale di errore all'indietro**, dal layer di uscita verso i layer più profondi, senza dover ricalcolare la loss da zero ad ogni passo.

Vettore del gradiente e aggiornamento dei pesi

Raccogliendo le derivate parziali rispetto a tutti i pesi del layer ℓ si ottiene il **gradiente** della loss rispetto alla matrice dei pesi $W^{(\ell)}$:

$$\nabla_{W^{(\ell)}} L = \Delta^{(\ell)} \otimes Z^{(\ell-1)}$$

dove $\Delta^{(\ell)} \in \mathbb{R}^{N^{(\ell)}}$ è il vettore dei delta del layer ℓ e $Z^{(\ell-1)} \in \mathbb{R}^{N^{(\ell-1)}}$ è il vettore degli output del layer precedente; $\otimes$ indica il prodotto esterno tra i due vettori, che produce una matrice di dimensione $N^{(\ell)} \times N^{(\ell-1)}$. Ogni elemento (i, j) di questa matrice è esattamente $\delta_i^{(\ell)} \cdot z_j^{(\ell-1)}$.

I pesi vengono quindi aggiornati tramite la discesa del gradiente:

$$W^{(\ell)} = W^{(\ell)} - \eta \nabla_{W^{(\ell)}} L$$

dove η è il learning rate. L'algoritmo procede layer per layer, dall'uscita verso l'ingresso, calcolando prima i delta tramite la formula ricorsiva e poi aggiornando i pesi con il gradiente corrispondente.

5.2 Convolutional Neural Network

Le *Convolutional Neural Network* (CNN) sono una classe di reti neurali ispirate al funzionamento della corteccia visiva dei mammiferi. Nascono con l'idea di processare immagini [23] e, a differenza delle MLP descritte nella sezione precedente, le CNN non prevedono l'utilizzo di un neurone per ogni pixel, ma organizzano i neuroni stessi in tre dimensioni così da creare una serie di matrici chiamate **kernel** o **filtri**. Questo le rende particolarmente efficaci nell'estrazione automatica di feature da dati strutturati,

come il segnale ECG monodimensionale considerato nel lavoro di questa tesi.

Come per l'MLP, l'apprendimento della rete avviene tramite la minimizzazione di una *loss function* (Cross-Entropy per la classificazione multi-classe, si veda la Sezione 5.1), utilizzando le medesime funzioni di attivazione (ReLU, Sigmoid, Softmax) e lo stesso algoritmo generale di *backpropagation* basato sulla chain rule. Ciò che cambia sostanzialmente rispetto all'MLP è la natura delle operazioni svolte da ciascun layer, che vedremo nel dettaglio in questa sezione.

Anche per la CNN, il numero di layer convoluzionali, il numero di filtri per layer, la dimensione dei kernel e la presenza/dimensione dei layer di pooling sono stati determinati tramite ottimizzazione con Optuna [1], in funzione della configurazione del task di classificazione.

5.2.1 Architettura di una CNN

Processo di convoluzione

Il *convolutional layer* è il componente principale di una CNN. Esso ha il compito di applicare tutti i kernel all'immagine in input tramite l'operazione di *convoluzione discreta*. Dato un input $I \in \mathbb{R}^{H \times W \times C}$ e un kernel $K \in \mathbb{R}^{m \times n}$, l'elemento in posizione (i, j) della matrice di output, chiamata *feature map*, è calcolato come:

$$(I * K)(i, j) = \sum_{k=0}^{m-1} \sum_{l=0}^{n-1} I(i+k, j+l) \cdot K(k, l)$$

Il filtro scorre sull'input con un passo definito dallo *stride*. Ogni filtro ha una quantità di pesi pari a $m \cdot n$ e sono condivisi su tutta l'immagine: questa proprietà, chiamata *weight sharing*, riduce drasticamente il numero di parametri rispetto a un layer completamente connesso e permette di apprendere feature locali indipendentemente dalla loro posizione.

Il risultato del layer convoluzionale è un insieme di *feature map*, una per ogni filtro applicato, che vengono poi passate alla funzione di attivazione.

Pooling Layer

I *pooling layer* hanno il compito di ridurre la dimensione spaziale delle feature map, rendendo la rete più efficiente e meno sensibile a piccole traslazioni dell'input (*invarianza traslazionale*).

Il tipo più comune è il *max pooling*: per ogni regione di dimensione $k \times k$ dell'input, viene selezionato il valore massimo. Un'alternativa è l'*average pooling*, che calcola la media dei valori nella regione. Il pooling non introduce nuovi parametri da apprendere, ma contribuisce a rendere le rappresentazioni più compatte e robuste.

5.2.2 Calcolo del gradiente in una CNN

A differenza di un MLP, in una CNN la struttura dei layer non è completamente connessa: i pesi dei filtri sono **condivisi** su tutta la mappa di attivazione (weight sharing) e le operazioni fondamentali sono convoluzioni, non semplici prodotti scalari. Per questo motivo, pur seguendo lo stesso principio generale della backpropagation basata sulla chain rule visto per l'MLP, il calcolo del gradiente differisce sostanzialmente tra le due architetture.

Struttura delle variabili

In un layer convoluzionale ℓ , l'input non è un vettore, ma un **tensore** a tre dimensioni $Z^{(\ell-1)} \in \mathbb{R}^{H \times W \times C}$, dove H e W sono le dimensioni spaziali e C è il numero di canali (o feature map). Il kernel è anch'esso un tensore $K^{(\ell)} \in \mathbb{R}^{m \times n \times C}$, con $m \times n$ dimensioni spaziali. L'output del layer convoluzionale, prima della funzione di attivazione, è la *feature map*:

$$A_{ij}^{(\ell)} = \sum_{p=0}^{m-1} \sum_{q=0}^{n-1} \sum_{c=0}^{C-1} K_{pqc}^{(\ell)} \cdot Z_{i+p, j+q, c}^{(\ell-1)} + b^{(\ell)}$$

dove (i, j) è la posizione spaziale nella feature map di output e $b^{(\ell)}$ è il bias. Dopo l'applicazione della funzione di attivazione f , si ottiene:

$$Z_{ij}^{(\ell)} = f\left(A_{ij}^{(\ell)}\right)$$

Segnale di errore nel layer convoluzionale

Per un layer convoluzionale ℓ , il *segnale di errore* δ associato alla posizione (i, j) è definito, analogamente al caso MLP, come la derivata parziale della loss rispetto alla preattivazione:

$$\delta_{ij}^{(\ell)} = \frac{\partial L}{\partial A_{ij}^{(\ell)}}$$

Se il layer ℓ è un **layer nascosto**, come avviene per tutti i layer convoluzionali, il delta deve tener conto di come ogni preattivazione $A_{ij}^{(\ell)}$ contribuisce a **tutte** le posizioni della feature map del layer successivo. Per la chain rule:

$$\delta_{ij}^{(\ell)} = f'\left(A_{ij}^{(\ell)}\right) \cdot \sum_s \sum_t \delta_{st}^{(\ell+1)} \cdot K_{i-s, j-t}^{(\ell+1)}$$

L'operazione di somma pesata sui delta del layer successivo corrisponde a una convoluzione tra $\delta^{(\ell+1)}$ e il kernel $K^{(\ell+1)}$ ruotato di 180°:

$$\delta_{ij}^{(\ell)} = f'\left(A_{ij}^{(\ell)}\right) \cdot \left(\delta^{(\ell+1)} * \text{rot}_{180}(K^{(\ell+1)})\right)_{ij}$$

La rotazione di 180° del kernel è una conseguenza diretta della chain rule applicata all'operazione di convoluzione: ogni peso K_{pq} ha contribuito alla preattivazione in posizione (i, j) tramite l'input nella posizione $(i+p, j+q)$, quindi il segnale di errore deve essere distribuito nella direzione opposta.

Gradiente rispetto ai pesi del filtro

Il gradiente della funzione di loss rispetto a un singolo peso $K_{pq}^{(\ell)}$ del kernel si calcola tramite la chain rule, sommando il contributo di tutte le posizioni (i, j) in cui quel peso è stato usato durante la convoluzione (*weight sharing*):

$$\frac{\partial L}{\partial K_{pq}^{(\ell)}} = \sum_i \sum_j \delta_{ij}^{(\ell)} \cdot Z_{i+p, j+q}^{(\ell-1)}$$

Questa espressione è una *cross-correlazione* tra il segnale di errore $\delta^{(\ell)}$ e la feature map di input $Z^{(\ell-1)}$. A differenza del MLP, in cui il gradiente rispetto a un peso è il semplice prodotto $\delta_i^{(\ell)} \cdot z_j^{(\ell-1)}$, qui è necessario sommare su tutte le posizioni spaziali a causa del weight sharing: lo stesso peso K_{pq} ha partecipato al calcolo di ogni elemento della feature map di output, quindi tutti questi contributi devono essere accumulati.

In forma vettoriale compatta, l'intero gradiente del kernel si scrive come:

$$\nabla_{K^{(\ell)}} L = \delta^{(\ell)} \star Z^{(\ell-1)}$$

dove $\star$ indica l'operazione di cross-correlazione tra le due matrici.

Gradiente rispetto al bias

Il gradiente rispetto al bias $b^{(\ell)}$ è la somma di tutti i delta del layer corrente su tutte le posizioni spaziali, poiché il bias è addizionato in ogni posizione:

$$\frac{\partial L}{\partial b^{(\ell)}} = \sum_i \sum_j \delta_{ij}^{(\ell)}$$

Backpropagation attraverso il Pooling Layer

Il pooling layer non contiene pesi da apprendere, ma è comunque necessario propagare il segnale di errore attraverso di esso. Nel caso del *max pooling*, durante il forward pass viene memorizzata la posizione del valore massimo in ogni regione $k \times k$ (*argmax*). Nella backprop, il delta viene assegnato esclusivamente all'elemento che aveva valore massimo, mentre tutti gli altri ricevono un contributo nullo:

$$\delta_{ij}^{(\ell)} = \begin{cases} \delta_{\lfloor i/k \rfloor, \lfloor j/k \rfloor}^{(\ell+1)} & \text{se } (i, j) \text{ era il massimo nella sua regione} \\ 0 & \text{altrimenti} \end{cases}$$

Nel caso dell'*average pooling*, il delta viene distribuito uniformemente su tutti gli elementi della regione:

$$\delta_{ij}^{(\ell)} = \frac{1}{k^2} \delta_{\lfloor i/k \rfloor, \lfloor j/k \rfloor}^{(\ell+1)}$$

Aggiornamento dei pesi

Una volta calcolati i gradienti per ogni layer, i pesi vengono aggiornati tramite la stessa regola di discesa del gradiente vista per l'MLP:

$$K^{(\ell)} = K^{(\ell)} - \eta \nabla_{K^{(\ell)}} L \quad b^{(\ell)} = b^{(\ell)} - \eta \frac{\partial L}{\partial b^{(\ell)}}$$

dove η è il learning rate. La struttura generale dell'algoritmo rimane quindi invariata rispetto al MLP; ciò che cambia è la **natura delle operazioni**: somme pesate scalari diventano cross-correlazioni e convoluzioni, dovuto alla geometria dei layer convoluzionali.

5.2.3 CNN applicate a segnali monodimensionali

Le CNN nascono per l'elaborazione di immagini bidimensionali, ma il loro meccanismo convoluzionale si può generalizzare a segnali monodimensionali come le serie temporali. Nel caso 1D, il filtro convoluzionale scorre lungo l'asse temporale anziché sullo spazio bidimensionale dell'immagine.

Convoluzione 1D

In una convoluzione 1D, abbiamo sempre il tensore $\mathbf{Z} \in \mathbb{R}^{H \times W \times C}$, ma il parametro H ha valore uno, mentre C dipende dai canali in ingresso, dodici nel nostro caso; i filtri seguono la stessa logica $\mathbf{K} \in \mathbb{R}^{n \times m \times C} \rightarrow \mathbf{K} \in \mathbb{R}^{n \times C}$. L'operazione di convoluzione 1D produce sempre una *feature map* preattivata $\mathbf{A}$ definita come:

$$A_i^{(\ell)} = \sum_{j=0}^{n-1} Z_{i+j}^{(\ell-1)} \cdot K_j^{(\ell)} + b^{(\ell)} \xrightarrow{\text{attivazione}} Z_i^{(\ell)} = f\left(A_i^{(\ell)}\right)$$

dove b è il bias e i scorre lungo la dimensione temporale. Estendendo a N filtri, si ottengono N feature map in uscita, ognuna specializzata nel rilevare un pattern morfologico diverso. Il segnale di errore δ si indica allo stesso modo, il calcolo invece risulta più semplice:

$$\delta_i^{(\ell)} = \frac{\partial L}{\partial A_i^{(\ell)}} = f'\left(A_i^{(\ell)}\right) \cdot \sum_j \delta_j^{(\ell+1)} \cdot K_{i-j}^{(\ell+1)}$$

questa operazione può essere semplificata esattamente come spiegato nella sezione precedente:

$$\delta_i^{(\ell)} = f' \left(A_i^{(\ell)} \right) \cdot \left(\delta^{(\ell+1)} * \text{rot}_{180^\circ} \left(K^{(\ell+1)} \right) \right)_i$$

5.2.4 Vantaggi per i segnali ECG

L'applicazione delle CNN 1D ai segnali ECG offre numerosi vantaggi rispetto agli approcci tradizionali basati su feature engineering manuale [12]:

- **Estrazione automatica delle feature:** la rete apprende autonomamente quali caratteristiche morfologiche (ampiezza e durata dell'onda P, complesso QRS, onda T, intervallo ST) sono discriminative per ogni classe, senza richiedere conoscenze a priori.
- **Invarianza locale:** grazie al pooling, la rete risulta robusta a piccole variazioni nella posizione temporale dei componenti del battito.
- **Gerarchia di rappresentazione:** i primi livelli convoluzionali apprendono pattern di basso livello (variazioni locali della forma d'onda), mentre i livelli più profondi combinano queste informazioni in rappresentazioni di alto livello (morfologie patologiche complesse).
- **Efficienza computazionale:** la condivisione dei pesi riduce il numero di parametri rispetto a una rete fully connected applicata allo stesso segnale.

5.3 Graph Convolutional Network con CNN Backbone

L'ultima e più complessa architettura proposta è una *Signed Graph Convolutional Network* che utilizza una CNN 1D, analoga a quella descritta nella Sezione 5.2, come *backbone* per l'estrazione delle feature da ciascuna delle 12 derivazioni del segnale ECG. A differenza della CNN standard, dove le

12 derivazioni sono trattate come canali di un unico tensore di input, in questa architettura la backbone elabora ciascuna derivazione *singolarmente e con pesi condivisi*, producendo un vettore di feature per ciascun nodo del grafo, poi, è lo strato di *message passing* [19] a modellare esplicitamente come queste rappresentazioni si relazionano tra le diverse derivazioni, sfruttando una topologia di grafo *signed* [7] costruita a partire dalla geometria delle derivazioni.

Come per l'MLP e la CNN, anche l'addestramento della GCN avviene tramite *backpropagation* basata sulla chain rule e discesa del gradiente, minimizzando la stessa Cross-Entropy Loss introdotta nella Sezione 5.1. Le funzioni di attivazione sono una ReLU, utilizzata nel *backbone* convoluzionale, e la *LeakyReLU* [24] nello strato di message passing 5.3.4.

Anche in questo caso, il numero di layer di message passing, la dimensione delle feature nodali e nascoste e il tipo di classificatore finale (lineare o MLP), sono stati determinati tramite ottimizzazione con *Optuna* [1], in funzione della configurazione specifica del task.

5.3.1 Estrazione delle feature nodali

Ogni segmento ECG in ingresso ha dimensione $(12, T)$, con $T = 500$ campioni corrispondenti a una finestra di un secondo campionata a 500 Hz centrata sul picco dell'onda R. Prima che il grafo venga costruito, ciascuna delle 12 derivazioni viene elaborata **singolarmente** da una CNN 1D condivisa (*LeadCNNEncoder*) [23], che produce per ogni derivazione un vettore di feature di dimensione fissata d_{node} . Essendo i pesi condivisi tra tutte le derivazioni, la rete apprende pattern morfologici generici (onda P, complesso QRS, onda T) indipendentemente dalla derivazione specifica; sarà poi il layer di message passing a modellare come queste feature si relazionano tra le derivazioni.

La backbone è composta da tre blocchi convoluzionali, ciascuno seguito da *Batch Normalization* [16] e attivazione ReLU, con *max pooling* dopo i

primi due blocchi:

Blocco 1: $\text{Conv1D}(1 \rightarrow 16, k = 7) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2)$

Blocco 2: $\text{Conv1D}(16 \rightarrow 32, k = 5) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2)$

Blocco 3: $\text{Conv1D}(32 \rightarrow d_{\text{node}}, k = 3) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{AdaptiveAvgPool1D}(1)$

L'ultimo strato di *average pooling adattivo* riduce l'output a un singolo valore per canale indipendentemente dalla lunghezza della sequenza in ingresso: questo rende la backbone svincolata da T , pur essendo la dimensione dei kernel stata scelta pensando esplicitamente a $T = 500$ campioni a 500 Hz (cioè 1 campione = 2 ms).

In particolare, la dimensione decrescente dei kernel nei tre blocchi ($7 \rightarrow 5 \rightarrow 3$) riflette la durata fisiologica attesa delle componenti dell'onda ECG:

- il kernel di dimensione 7 nel primo blocco corrisponde a una finestra ricettiva di 14 ms sul segnale originale, sufficientemente fine da seguire i bordi ripidi del complesso QRS, che dura tipicamente 80–120 ms (cioè 40–60 campioni);
- il kernel di dimensione 5 nel secondo blocco corrisponde a 10 ms sulla rappresentazione già sotto-campionata dal primo MaxPool;
- il kernel di dimensione 3 nel terzo blocco raffina ulteriormente la rappresentazione prima del pooling globale.

I due MaxPool intermedi riducono progressivamente la lunghezza temporale $T = 500 \rightarrow 250 \rightarrow 125$ prima dell'*AdaptiveAvgPool1D* finale: anche all'ultimo strato convoluzionale la rete osserva quindi un contesto temporale di 125 campioni (250 ms), sufficiente a contenere l'intero complesso QRS.

5.3.2 Modellazione del Grafo ECG basata su Vettori di Derivazione 3D

Le 12 derivazioni sono modellate come nodi di un grafo $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, dove $\mathcal{V} = \{v_1, \dots, v_{12}\}$ rappresenta le derivazioni nell'ordine standard:

$$\mathcal{V} = \{\text{I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6}\} \quad (5.1)$$

Invece di lasciare che la rete apprenda la struttura del grafo in modo autonomo, si è scelto di imporre un *bias induttivo spaziale fisso*, derivato dalla reale geometria delle derivazioni [25, 9], che vincola il *message passing* alle leggi fisiche della propagazione del potenziale elettrico cardiaco.

L'attività elettrica del cuore può essere approssimata da un dipolo elettrico equivalente, espresso da un vettore cardiaco istantaneo $\vec{D}(t) \in \mathbb{R}^3$. Ciascuna derivazione $i \in \mathcal{V}$ misura la proiezione di tale dipolo lungo il proprio asse di osservazione anatomico 1.2, identificato da un vettore unitario di orientamento $\vec{u}_i \in \mathbb{R}^3$:

$$V_i(t) \approx \vec{D}(t) \cdot \vec{u}_i \quad (5.2)$$

Derivazioni Periferiche. Le derivazioni degli arti (I, II, III, aVR, aVL, aVF) sono vincolate al solo piano frontale ($z_i = 0$). I loro vettori unitari sono definiti calcolando seno e coseno dell'angolo di orientamento θ_i stabilito nel sistema esassiale di Einthoven-Goldberger [9]:

$$\begin{cases} x_i = \cos(\theta_i) \\ y_i = \sin(\theta_i) \\ z_i = 0 \end{cases} \quad (5.3)$$

Derivazioni Precordiali. Le 6 derivazioni precordiali sono unipolari e non "ancorate" a un piano come le periferiche; misurano il potenziale elettrico tra un elettrodo sulla parete toracica e il *Terminale Centrale di Wilson* (WCT), posizionato all'origine dello spazio tridimensionale (0, 0, 0) e calcolato come punto medio dei tre elettrodi periferici. Adottando la

convenzione cartesiana toracica di Malmivuo-Plonsey [25] (asse $+X$ verso sinistra, $+Y$ verso i piedi, $+Z$ verso la parete toracica anteriore), la posizione di ciascun elettrodo V_i è definita da un angolo di *azimuth* θ_h e uno di *elevazione* ϕ_v , convertiti in coordinate cartesiane unitarie:

$$\begin{cases} x_i = \cos(\phi_v) \cdot \cos(\theta_h) \\ y_i = \sin(\phi_v) \\ z_i = \cos(\phi_v) \cdot \sin(\theta_h) \end{cases} \quad (5.4)$$

Come mostrato in Tabella 5.1, muovendosi da V1 a V6 la componente anteriore z decade progressivamente da 0.923 a 0.000, mentre la componente laterale x cresce da -0.342 a $+0.985$: per V_6 si ottiene un vettore $\vec{u}_{V6} \approx (0.985, -0.174, 0.000)^T$ quasi parallelo a $\vec{u}_1 = (1.000, 0.000, 0.000)^T$, confermando matematicamente l'evidenza clinica per cui derivazione I e V6 osservano la medesima regione cardiaca (parete laterale sinistra).

Tabella 5.1: Coordinate tridimensionali unitarie e orientamenti degli assi di osservazione per le 12 derivazioni cardiache.

Derivazione	Azimuth (θ_h)	Elevazione (ϕ_v)	x (Sx)	y (Inf)	z (Ant)
I	0°	0°	1.000	0.000	0.000
II	$+60^\circ$	0°	0.500	0.866	0.000
III	$+120^\circ$	0°	-0.500	0.866	0.000
aVR	-150°	0°	-0.866	-0.500	0.000
aVL	-30°	0°	0.866	-0.500	0.000
aVF	$+90^\circ$	0°	0.000	1.000	0.000
V1	$+110^\circ$	$+10^\circ$	-0.342	0.174	0.923
V2	$+100^\circ$	$+10^\circ$	-0.174	0.174	0.969
V3	$+80^\circ$	$+5^\circ$	0.174	0.087	0.981
V4	$+60^\circ$	0°	0.500	0.000	0.866
V5	$+30^\circ$	-5°	0.866	-0.087	0.492
V6	0°	-10°	0.985	-0.174	0.000

5.3.3 Costruzione del Grafo Signed

La correlazione teorica attesa tra due derivazioni i e j è direttamente proporzionale all'allineamento dei rispettivi vettori di osservazione. La matrice di similitudine $S \in \mathbb{R}^{12 \times 12}$ è calcolata tramite *cosine similarity*. poiché i vettori $\vec{u}_i$ sono normalizzati a norma unitaria, essa si riduce al prodotto scalare tridimensionale:

$$S_{ij} = \vec{u}_i^T \vec{u}_j = x_i x_j + y_i y_j + z_i z_j \in [-1, 1] \quad (5.5)$$

In questa architettura si è scelto di preservare l'informazione contenuta nelle correlazioni negative, dato che, coppie di derivazioni con vettori di osservazione quasi antiparalleli (ad esempio I e aVR, con $S_{ij} \approx -0.87$), osservano la stessa attività elettrica con polarità invertita, questa relazione di **discordanza** è informativa tanto quanto una relazione diretta, in particolar modo per il task di rilevazione del malposizionamento degli elettrodi.

Il layer **GCNConv** di Kipf e Welling [19], tuttavia, normalizza i pesi degli archi per il grado dei nodi ($\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$), che richiede pesi non negativi. Per non perdere l'informazione delle correlazioni negative pur rispettando questo vincolo, si è adottato un approccio tramite *signed graph*, adeguando il lavoro di Derr et al. (*Signed Graph Convolutional Networks*, ICDM 2018) [7]. In pratica, invece di un unico grafo, si costruiscono **due sottografi** distinti sulle 12 derivazioni, entrambi a pesi non negativi:

$$A_{ij}^+ = \begin{cases} S_{ij} & \text{se } S_{ij} > \varepsilon \\ 0 & \text{altrimenti} \end{cases} \quad A_{ij}^- = \begin{cases} |S_{ij}| & \text{se } S_{ij} < -\varepsilon \\ 0 & \text{altrimenti} \end{cases} \quad (5.6)$$

dove $\varepsilon > 0$ è una soglia di tolleranza sotto la quale due derivazioni sono considerate geometricamente non correlate (nessun arco tra le derivazioni). Un valore di ε più alto produce un grafo più sparso, necessario al fine di regolarizzare il modello permettendo l'apprendimento, che data la dimensione contenuta della rete e del numero di nodi, rischiava di essere compromesso. Poiché $S_{ii} = 1 \ \forall i$ per costruzione, è stato scelto di includere i *self-loop* solamente nel grafo A^+ e non in A^- .

5.3.4 Message Passing Signed

Sui due sottografi A^+ e A^- operano due layer **GCNConv** [19] indipendenti (senza aggiunta automatica di self-loop, poiché già presenti in A^+ e assenti in A^-). Dato lo stato dei nodi $H^{(\ell-1)}$ al layer $\ell - 1$ (con $H^{(0)}$ pari alle feature prodotte dalla CNN backbone), il blocco di message passing signed calcola:

$$H^{+(\ell)} = \text{GCNConv}_\ell^+(H^{(\ell-1)}, A^+) \quad H^{-(\ell)} = \text{GCNConv}_\ell^-(-H^{(\ell-1)}, A^-) \quad (5.7)$$

Nel ramo negativo le feature in ingresso vengono **negate** ($-H^{(\ell-1)}$) prima della convoluzione, in modo da rappresentare esplicitamente l'inversione di polarità attesa fisiologicamente tra derivazioni discordi, coerentemente con la formulazione originale del signed message passing [7]. I due contributi vengono quindi **concatenati** (anziché sommati algebricamente, per evitare che valori di grande modulo in un ramo possano cancellare i contributi dell'altro) e proiettati alla dimensione desiderata tramite una trasformazione lineare, seguita da una *Layer Normalization* [3] che stabilizza la rappresentazione anche per i nodi con grado nullo nel sottografo negativo:

$$H^{(\ell)} = \text{LayerNorm}\left(W^{(\ell)} [H^{+(\ell)} \parallel H^{-(\ell)}] + b^{(\ell)}\right) \quad (5.8)$$

dove $\parallel$ indica la concatenazione. L'output di ciascun blocco viene poi passato attraverso un'attivazione *LeakyReLU* [24], scelta per evitare di annullare i contributi negativi dei rami.

5.3.5 Calcolo del Gradiente nella GCN

Come nel caso della CNN (Sezione 5.2), anche nella GCN il calcolo del gradiente segue lo stesso principio generale della backpropagation basato sulla chain rule, ma la natura dell'operazione di aggregazione cambia ulteriormente: la convoluzione spaziale è sostituita da un'*aggregazione pesata sui vicini del grafo*, definita dalla topologia fissa A^+ e A^- (Sezione 5.3.2).

Struttura delle variabili

Ricordando la formulazione di Kipf e Welling [19], ciascun layer GCNConv_ℓ operante su un sottografo $A^\pm$ calcola:

$$\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} \in \mathbb{R}^{12 \times 12}$$

dove $\tilde{A} = A^\pm$ (con i self-loop già inclusi in A^+ , secondo quanto definito nella Sezione 5.3.3) e $\tilde{D}$ è la matrice diagonale dei gradi. Poiché $\hat{A}$ dipende esclusivamente dalla geometria fissa delle derivazioni, si tratta di un operatore **costante e non addestrabile**. La preattivazione del layer, per i nodi al layer $H^{(\ell-1)} \in \mathbb{R}^{12 \times d_{\ell-1}}$, è quindi:

$$A^{(\ell)} = \hat{A} H^{(\ell-1)} W^{(\ell)} \in \mathbb{R}^{12 \times d_\ell}$$

e l'output attivato $H^{(\ell)} = f(A^{(\ell)})$, dove f è la *LeakyReLU* introdotta nella Sezione 5.3.4.

Segnale di errore nel layer di message passing

Analogamente ai casi MLP e CNN, definiamo il segnale di errore per il nodo i al layer ℓ come:

$$\delta_i^{(\ell)} = \frac{\partial L}{\partial A_i^{(\ell)}}$$

Poiché $A^{(\ell)} = \hat{A} H^{(\ell-1)} W^{(\ell)}$, ogni riga $H_i^{(\ell-1)}$ contribuisce alla preattivazione di **tutti** i nodi j tali che $\hat{A}_{ji} \neq 0$, cioè di tutti i vicini di i nel grafo (analogamente a come, in una CNN, ogni pixel contribuisce alla preattivazione di tutte le posizioni del kernel che lo contiene). Applicando la chain rule, la matrice dei delta del layer $\ell - 1$ si ottiene come:

$$\Delta^{(\ell-1)} = f'(A^{(\ell-1)}) \odot \left(\hat{A}^T \Delta^{(\ell)} W^{(\ell)T} \right)$$

dove $\odot$ indica il prodotto elemento per elemento. Essendo $\hat{A}$ simmetrica per costruzione, si ha $\hat{A}^T = \hat{A}$, per cui:

$$\Delta^{(\ell-1)} = f'(A^{(\ell-1)}) \odot \left(\hat{A} \Delta^{(\ell)} W^{(\ell)T} \right)$$

Questa espressione gioca, nella GCN, lo stesso ruolo giocato dalla convoluzione con il kernel ruotato di 180 nella CNN (Sezione 5.2), dato che, l'operatore $\hat{A}$, essendo simmetrico, ridistribuisce il segnale di errore ai vicini di ciascun nodo esattamente nella stessa direzione in cui l'informazione era stata originariamente aggregata in avanti.

Gradiente rispetto ai pesi e al bias

Dato che $A^{(\ell)} = \hat{A} H^{(\ell-1)} W^{(\ell)}$, il gradiente della loss rispetto alla matrice dei pesi $W^{(\ell)}$ si ottiene applicando la chain rule al prodotto matriciale:

$$\nabla_{W^{(\ell)}} L = \left(\hat{A} H^{(\ell-1)} \right)^T \Delta^{(\ell)}$$

Il gradiente rispetto al bias $b^{(\ell)}$, introdotto nella proiezione lineare della Sezione 5.3.4, si calcola invece come somma dei delta su tutti i nodi, esattamente come nel caso di MLP e CNN:

$$\frac{\partial L}{\partial b^{(\ell)}} = \sum_{i=1}^{12} \delta_i^{(\ell)}$$

Poiché l'output del blocco di message passing è la concatenazione $[H^{+(\ell)} \parallel H^{-(\ell)}]$ dei due rami, il segnale di errore $\Delta^{(\ell)}$ proveniente dalla Layer Normalization viene innanzitutto suddiviso per colonne nei due contributi $\Delta^{+(\ell)}$ e $\Delta^{-(\ell)}$, che vengono poi retropropagati separatamente attraverso i rispettivi layer GCNConv^+ e GCNConv^- secondo le formule precedenti. Per il ramo negativo, essendo l'input al forward pass $-H^{(\ell-1)}$ anziché $H^{(\ell-1)}$, la chain rule introduce un fattore -1 nella propagazione del delta verso $H^{(\ell-1)}$.

Gradiente rispetto ai pesi della backbone

I pesi della CNN backbone (Sezione 5.3.1) sono **condivisi tra le 12 derivazioni**: lo stesso *LeadCNNEncoder* viene applicato singolarmente a ciascuna delle 12 sequenze in ingresso prima della costruzione del grafo. Questo è concettualmente identico al *weight sharing* spaziale già visto per la CNN (Sezione 5.2), ma applicato lungo la dimensione delle derivazioni

anziché lungo lo spazio o il tempo: lo stesso peso K^{backbone} contribuisce al calcolo della feature nodale di tutte e 12 le derivazioni, quindi il suo gradiente totale è la somma dei contributi calcolati separatamente per ciascuna derivazione v :

$$\nabla_{K^{\text{backbone}}} L = \sum_{v=1}^{12} \nabla_{K^{\text{backbone}}} L^{(v)}$$

dove $\nabla_{K^{\text{backbone}}} L^{(v)}$ è il gradiente calcolato tramite le formule di backpropagation della CNN 1D (Sezione 5.2) a partire dal delta ricevuto dal nodo v del grafo, cioè dalla prima riga della matrice $\Delta^{(0)}$ retropropagata dal primo layer di message passing fino all'uscita della backbone.

Aggiornamento dei pesi

Una volta calcolati tutti i gradienti, i pesi della GCN (matrici $W^{(\ell)}$ e bias $b^{(\ell)}$ dei layer di message passing, kernel e bias della backbone condivisa, pesi del classificatore finale) vengono aggiornati con la medesima regola di discesa del gradiente utilizzata per MLP e CNN:

$$W^{(\ell)} = W^{(\ell)} - \eta \nabla_{W^{(\ell)}} L \quad K^{\text{backbone}} = K^{\text{backbone}} - \eta \nabla_{K^{\text{backbone}}} L$$

La struttura generale dell'algoritmo di ottimizzazione rimane quindi invariata rispetto a MLP e CNN: ciò che cambia è la natura dell'operatore che modella la dipendenza tra le unità che danno informazione e le altre da cui ricevono informazione: somme pesate scalari nell'MLP, pesi condivisi e convoluzioni nella CNN, e infine un operatore di aggregazione $\hat{A}$ fissato dalla geometria delle derivazioni nella GCN. Il principio della chain rule e la discesa del gradiente restano invece gli stessi in tutte e tre le architetture, a conferma di come queste rappresentino, più che tre metodi distinti, tre diversi modi di vedere e risolvere un problema.

5.3.6 Pooling Globale e Classificazione

Dopo L layer di message passing, le rappresentazioni nodali $H^{(L)} \in \mathbb{R}^{12 \times d_{\text{hidden}}}$ vengono aggregate in un unico **embedding di grafo**, rappresentativo del-

l'intero ECG a 12 derivazioni, tramite la concatenazione di *global mean pooling* e *global max pooling*:

$$e_G = [\text{mean}_i(H_i^{(L)}) \parallel \max_i(H_i^{(L)})] \in \mathbb{R}^{2d_{\text{hidden}}} \quad (5.9)$$

Utilizzare in coppia media e massimo fornisce una rappresentazione più robusta rispetto all'uso della sola media, catturando sia il comportamento aggregato dell'insieme delle derivazioni sia le attivazioni più "forti" su singoli nodi. L'embedding e_G viene infine passato a un classificatore finale, che può essere un semplice layer lineare oppure un piccolo MLP (lineare $\rightarrow$ ReLU $\rightarrow$ Dropout [39] $\rightarrow$ lineare) a seconda della complessità richiesta dal task, per produrre i *logits* sulle C classi (normale + tipologie di inversione considerate). Il gradiente attraverso questo strato finale si calcola con le medesime formule già viste per l'MLP (Sezione 5.1), a partire dal delta del layer di uscita fino ai delta dei nodi $H_i^{(L)}$, retropropagati poi attraverso gli operatori di mean/max pooling (in modo analogo al max/average pooling spaziale della CNN, Sezione 5.2) e infine attraverso i layer di message passing secondo quanto derivato nella Sezione 5.3.5.

Capitolo 6

Validazione sperimentale e risultati

In questo capitolo vengono descritte la metodologia di valutazione adottata e l'insieme dei test sperimentali eseguiti per verificare le prestazioni dei modelli sviluppati. La discussione critica dei risultati, il confronto tra le configurazioni e le relative considerazioni sono rimandate al capitolo successivo (7); qui ci si concentra sul *cosa* è stato testato e sul *come*, in modo da fornire il contesto necessario a interpretare correttamente i dati riportati in seguito.

6.1 Metodologia di valutazione

A differenza della fase di training, in cui ogni registrazione ECG contribuisce al dataset con un numero limitato di battiti (2 per registrazione, si veda il Capitolo 4), la fase di test è stata progettata per valutare la correttezza della predizione a livello di **intera registrazione**, e non del singolo battito. Questa scelta è motivata dal fatto che un singolo battito può essere classificato erroneamente a causa di rumore, morfologia atipica o errori di allineamento del picco R, senza che questo rifletta un reale errore nel posizionamento degli elettrodi.

Lo script `test.py` implementa questa logica secondo i seguenti passi:

1. **Caricamento lazy dei segmenti:** i segmenti (battiti già estratti durante la fase di preparazione del dataset) vengono caricati da disco batch per batch tramite un Dataset PyTorch (`ECGFileDataset`), evitando di tenere l'intero dataset di test in memoria RAM. Questa feature si è resa necessaria per evitare terminazioni del processo (Out-Of-Memory) su dataset di dimensioni maggiori.
2. **Normalizzazione e controllo di validità:** per ogni segmento viene verificata la forma attesa ($12 \text{ derivazioni} \times \text{lunghezza attesa}$) e l'assenza di valori NaN; viene poi applicata una normalizzazione *z-score* per canale. I segmenti non validi (file mancanti, forma errata, valori non numerici) vengono scartati e non contribuiscono al voto finale della registrazione a cui appartengono.
3. **Inferenza batch per batch:** il modello, con i pesi caricati da un checkpoint (`.pt`), esegue l'inferenza su ciascun batch di segmenti validi.
4. **Aggregazione per majority voting a livello di registrazione:** le predizioni dei singoli segmenti appartenenti alla stessa registrazione (`ecg_id`) vengono raggruppate; la classe predetta per l'intera registrazione è quella più votata tra i suoi segmenti. Viene inoltre calcolato il rapporto tra il numero di voti della classe vincente e il numero totale di segmenti validi della registrazione (`confidence_ratio`), riportato a titolo informativo nel riepilogo dei risultati, con soglia di riferimento del 50%.

I risultati dell'esecuzione di `test.py` sono due:

- nel terminale, vengono stampati il *classification report* (precision, recall, f1-score per classe) e la matrice di confusione, calcolati a livello di registrazione;
- viene salvato un file `test_recordings_summary.csv` con una riga per registrazione, contenente: identificativo, numero di segmen-

ti validi utilizzati, etichetta reale, etichetta predetta, rapporto di confidenza ed esito (True/False).

6.2 Pulizia del training set

Come accennato nel Capitolo 4, il training set costruito da `dataset_builder.py` include solo 2 battiti per registrazione. Se da un lato questo limita il costo computazionale in fase di training, dall'altro rende difficile qualunque tentativo di stabilire se una registrazione presente nel database sorgente (PTB-XL, Georgia) sia effettivamente affetta da uno scambio di elettrodi reale, oppure sia stata etichettata in modo scorretto; un singolo battito anomalo non è una prova sufficiente.

Per risolvere questo problema è stato sviluppato lo script `find_mislabeled_recordings.py`, che applica alle registrazioni del training set la stessa procedura di valutazione a livello di intera registrazione descritta in Sezione 6.1, ma partendo dal segnale grezzo (non dai soli 2 battiti già estratti). Suddivisa in due fasi:

1. **Predizione grezza** (P_{raw}): a partire dal segnale grezzo della registrazione (così com'è nel database sorgente, quindi assumendo che sia corretta/normale), vengono estratti tutti i battiti validi (rilevamento dei picchi R e segmentazione) e si esegue l'inferenza su ciascuno di essi, aggregando con majority voting. Se $P_{raw} \neq \text{normal}$, la registrazione viene marcata come *candidata*. Questo perchè il modello, pur osservando la registrazione nella forma in cui è presente nel database, ritiene comunque di riconoscere un malposizionamento di tipo P_{raw} .
2. **Test di conferma** ($P_{confirm}$): per ogni registrazione candidata, viene applicata artificialmente la trasformazione corrispondente a P_{raw} (cioè lo scambio di elettrodi previsto), a tutti i battiti della registrazione, e si ripete l'inferenza con majority voting, ottenendo $P_{confirm}$. Se $P_{confirm}$ torna a essere **normal**, si ha un forte indizio che la registrazione possedesse già in origine lo scambio P_{raw} . Applicare sinte-

ticamente lo stesso scambio lo ha di fatto "annullato", riportando la geometria delle derivazioni ad uno stato normale. In questo caso la registrazione viene marcata come *confermata*.

L'output dello script è un file CSV (una riga per registrazione analizzata) con predizione grezza, esito della candidatura ed esito del test di conferma. Le registrazioni identificate come *confermate*, partendo dalle previsioni dei modelli allenati per il riconoscimento di una **singola** classe di scambio, sono quelle rimosse dal training set per ottenere la variante *reduced* del dataset, in opposizione alla variante *original* (dataset di training non filtrato).

6.3 Configurazioni sperimentali

I test descritti in questo capitolo sono stati ripetuti sistematicamente combinando tre fattori, che andranno a definire la struttura delle directory:

Modello utilizzato `original`, indica che il modello è stato allenato con il dataset `original`, oppure `reduced` indica che il modello è stato allenato con il dataset ridotto, come spiegato nella sezione 6.2;

Numero di classi organizza i modelli addestrati per distinguere 2, 3, 4 o 5 classi; in tutti i casi è presente la classe `normal` più le combinazioni di scambio derivazioni considerate, ad esempio `LA_LL`, `RA_LA`, `RA_LL`, `V1_V2`, `V2_V3`, ecc.);

Dataset di test indica quale dataset è stato testato: *split test* interno, creato dai dataset PTB-XL/Georgia (come spiegato nella sezione 4.5.4, oppure il dataset esterno denominato "**China**" (sezione 4.7), utilizzato esclusivamente in fase di test training per valutare la capacità di generalizzazione dei modelli su una popolazione e un protocollo di acquisizione differenti, e infine `china_mod` indica il dataset dopo la rimozione delle registrazioni probabilmente errate (selezionate come per il dataset di training 6.2).

La struttura delle cartelle dei test eseguiti, riportata in Figura 6.1, riflette esattamente queste tre scelte, creando un'organizzazione semplice e intuitiva.




Figura 6.1: Struttura delle directory dei test eseguiti.

È importante sottolineare che gli script `test.py` e `find_mislabeled_recordings.py` utilizzati sono gli stessi in tutte le configurazioni: ciò che cambia sono i pesi del modello caricati (`-weights`), l'elenco delle classi (`-classes`, nell'ordine usato in training) e la cartella dati fornita in input (`-data_dir`, o gli argomenti `-china_root/-china_csv` per il dataset esterno). Le differenze nei risultati riportati nel capitolo successivo sono quindi imputabili esclusivamente alle differenze tra le configurazioni sopra descritte, e non a differenze nella procedura di valutazione.

6.4 Risultati numerici

Dato l'elevato numero di combinazioni testate (variante del dataset $\times$ numero di classi $\times$ dataset di test), non tutte le esecuzioni sono riportate per esteso in questa tesi; nel capitolo *Discussione dei risultati* andranno selezionate e commentate le combinazioni più rilevanti.

6.4.1 split di test tra modelli

Per prima, viene mostrata la tabella contenente le precisioni raggiunte dai vari tipi di modelli allenati con il dataset di training originale; il test è stato eseguito sullo split di test generato a partire da *PTB-XL/Georgia*:

Tabella 6.1: Precisioni calcolate su modelli allenati con dataset di training originale

Classe	Acc. CNN (%)	Acc. MLP (%)	Acc. GCN (%)
normal LA_LL	99.75	97.13	95.73
normal RA_LA	99.85	99.60	99.41
normal RA_LL	99.94	99.78	99.04
normal V1_V2	99.51	98.70	93.29
normal V2_V3	98.61	96.82	89.34
normal V3_V4	99.66	n.d.	n.d.
normal V4_V5	98.73	n.d.	n.d.
normal V5_V6	98.42	n.d.	n.d.
normal LA_LL-RA_LL	98.83	n.d.	93.91
normal LA_LL-V3_V4	98.05	94.13	n.d.
normal RA_LA-LA_LL	97.81	96.45	95.27
normal RA_LA-RA_LL	99.72	94.71	99.10
normal V1_V2-V2_V3	97.99	n.d.	89.41
normal V2_V3-RA_LA	97.87	n.d.	n.d.

6.4.2 split di test tra *original* e *reduced*

Qui vengono comparate vari modelli della *cnn* allenati con il dataset di training originale e ridotto:

Tabella 6.2: Precisioni calcolate su modelli allenati con dataset di training originale e ridotto

Classe	Acc. original (%)	Acc. reduced (%)
normal LA_LL	99.75	98.93
normal RA_LA	99.85	99.84
normal RA_LL	99.94	99.81
normal V1_V2	99.51	99.65
normal V2_V3	98.61	99.09
normal V3_V4	99.66	99.56
normal V4_V5	98.73	98.71
normal V5_V6	98.42	99.05
normal LA_LL-RA_LL	98.83	96.94
normal LA_LL-V3_V4	98.05	97.13
normal RA_LA-LA_LL	97.81	97.32
normal RA_LA-RA_LL	99.72	99.68
normal V1_V2-V2_V3	97.99	97.79
normal V2_V3-RA_LA	97.87	98.68

6.4.3 database esterno

Qui vengono mostrati i test eseguiti sul database "*china*" (Sezione 4.7), sia con modelli addestrati con il dataset di training originale, sia con il dataset ridotto.

La tabella riporta le precisioni ottenute sui modelli addestrati con il dataset originale e ridotto a confronto. L'ultima colonna indica il valore riportato nei file `tot.txt`, relativo ai casi predetti con inversione e riconfermati dal

test presente in `find_mislabeled_recordings.py`.

Tabella 6.3: Precisioni dei modelli addestrati con il dataset originale e ridotto, testati su *china*

Classe	Original			Reduced		
	Acc.	Acc. R	Riconf.	Acc.	Acc. R	Riconf.
normal LA_LL	99.57	94.68	178/188	98.70	55.99	318/568
normal RA_LA	99.74	64.04	73/114	99.55	51.53	101/196
normal RA_LL	99.84	56.52	39/69	99.79	68.82	64/93
normal V1_V2	99.40	59.39	155/261	99.21	67.83	234/345
normal V2_V3	96.98	29.95	396/1322	98.40	56.67	395/697
normal V3_V4	98.73	59.21	328/554	99.04	76.61	321/419
normal V4_V5	97.89	39.98	369/923	97.48	33.82	372/1100
normal V5_V6	96.86	75.25	371/493	98.10	76.72	636/829
normal LA_LL-RA_LL	98.35	68.52	494/721	95.68	20.76	392/1888
normal LA_LL-V3_V4	96.82	42.03	585/1392	95.72	36.43	682/1872
normal RA_LA-LA_LL	96.15	29.69	500/1684	96.12	26.59	451/1696
normal RA_LA-RA_LL	99.66	78.38	116/148	99.76	80.37	86/107
normal V1_V2-V2_V3	97.16	35.40	440/1243	96.25	27.80	456/1640
normal V2_V3-RA_LA	97.05	35.07	431/1229	97.87	45.48	423/930

6.4.4 database esterno modificato

Il database *china* modificato è stato ottenuto applicando all'1% delle registrazioni l'inversione corrispondente alla classe indicata. Per ogni configurazione sono stati utilizzati tre *seed* di randomizzazione ('42', '17' e '30'). I modelli sono tutti addestrati con il dataset di training originale. Le tabelle riportano le statistiche mostrate nei file `test.png`; le colonne relative alla classe indicata nella configurazione sono abbreviate con "classe".

Per valutare le prestazioni dei modelli sulla classe di scambio si fa uso delle seguenti metriche standard di classificazione, derivate dalla matrice di confusione.

Matrice di confusione La matrice di confusione confronta le predizioni del modello con i valori reali (*ground truth*), distinguendo quattro casi per la classificazione binaria:

- **TP** (*True Positive*): il modello identifica correttamente un caso appartenente alla classe di scambio;
- **FN** (*False Negative*): il modello non riconosce un caso reale della classe, classificandolo erroneamente come non appartenente;
- **FP** (*False Positive*): il modello classifica come appartenente alla classe un caso che in realtà non lo è;
- **TN** (*True Negative*): il modello riconosce correttamente un caso come non appartenente alla classe.

Da questi quattro valori si derivano direttamente tutte le metriche riportate di seguito.

Accuracy Rappresenta la percentuale di predizioni corrette sul totale delle registrazioni:

$$\frac{TP + TN}{TP + TN + FP + FN} \quad (6.1)$$

Essendo la classe di scambio fortemente minoritaria rispetto al totale delle registrazioni, l'accuracy tende a essere molto alta anche in presenza di errori significativi sulla classe di interesse; per questo motivo è necessario affiancarla ad altre metriche.

Precision Indica, tra le registrazioni classificate come appartenenti alla classe di scambio, quante lo sono realmente:

$$\frac{TP}{TP + FP} \quad (6.2)$$

Una precisione bassa segnala un numero elevato di falsi positivi.

Recall Indica, tra le registrazioni realmente appartenenti alla classe di scambio, quante sono state correttamente individuate dal modello:

$$\frac{TP}{TP + FN} \quad (6.3)$$

Un recall alto indica che il modello individua la quasi totalità dei casi reali, anche a costo di un maggior numero di falsi positivi.

F1-score È la media armonica di precisione e recall, particolarmente utile quando le due metriche assumono valori in contrasto tra loro:

$$2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (6.4)$$

Tabella 6.4: Accuracy e metriche per classe sui test con *china* modificato

Configurazione	Seed	Accuracy (%)	Classe di scambio		
			Precisione	Recall	F1
LA_LL	42	99.91	.9778	.9362	.9565
LA_LL	17	99.91	.9776	.9267	.9515
LA_LL	30	99.92	.9778	.9385	.9578
RA_LA	42	99.93	.9338	1.0000	.9658
RA_LA	17	99.93	.9358	1.0000	.9669
RA_LA	30	99.93	.9338	1.0000	.9658
RA_LL	42	99.96	.9570	1.0000	.9780
RA_LL	17	99.96	.9570	1.0000	.9780
RA_LL	30	99.96	.9570	1.0000	.9780
V1_V2	42	99.88	.8974	.9929	.9428
V1_V2	17	99.88	.8974	.9929	.9428
V1_V2	30	99.88	.8962	1.0000	.9453
V2_V3	42	97.98	.3310	.9953	.4968
V2_V3	17	97.98	.3305	.9953	.4962
V2_V3	30	97.98	.3307	.9929	.4962
V3_V4	42	99.49	.6667	.9882	.7962
V3_V4	17	99.50	.6672	.9905	.7973
V3_V4	30	99.49	.6661	.9905	.7966
V4_V5	42	98.87	.4695	1.0000	.6390
V4_V5	17	98.87	.4694	.9976	.6384
V4_V5	30	98.87	.4695	1.0000	.6390
V5_V6	42	98.39	.3818	.9929	.5515
V5_V6	17	98.39	.3827	.9953	.5529
V5_V6	30	98.39	.3825	.9929	.5523

Tabella 6.5: Matrici di confusione sui test con *china* modificato

Configurazione	Seed	TP	FN	FP	TN
LA_LL	42	396	27	9	41874
LA_LL	17	392	31	9	41874
LA_LL	30	397	26	9	41874
RA_LA	42	423	0	30	41853
RA_LA	17	423	0	29	41854
RA_LA	30	423	0	30	41853
RA_LL	42	423	0	19	41864
RA_LL	17	423	0	19	41864
RA_LL	30	423	0	19	41864
V1_V2	42	420	3	48	41835
V1_V2	17	420	3	48	41835
V1_V2	30	423	0	49	41834
V2_V3	42	421	2	851	41032
V2_V3	17	421	2	853	41030
V2_V3	30	420	3	850	41033
V3_V4	42	418	5	209	41674
V3_V4	17	419	4	209	41674
V3_V4	30	419	4	210	41673
V4_V5	42	423	0	478	41405
V4_V5	17	422	1	477	41406
V4_V5	30	423	0	478	41405
V5_V6	42	420	3	680	41203
V5_V6	17	421	2	679	41204
V5_V6	30	420	3	678	41205

6.4.5 modifica della soglia

Per alcune classi che presentano una *precision* molto bassa, è stato riprodotto il test con una soglia di confidenza più grande. In questo caso è stata scelta una soglia del 90% (il modello deve predire almeno il 90% dei segmenti con una stessa classe, altrimenti la registrazione viene scartata).

Tabella 6.6: Matrici di confusione sui test con *china* modificato

Configuraziones	TP	FN	FP	TN
V2_V3	410	1	483	39953
V3_V4	410	1	82	40996
V4_V5	421	0	261	40468
V5_V6	409	3	211	38509

Capitolo 7

Discussione dei risultati

In questo capitolo verranno discussi i risultati presentati nel capitolo precedente e come questi hanno definito le scelte per l'avanzamento del progetto di tesi.

Scelta dell'architettura principale. Tra le tre architetture mostrate (MLP, CNN, GCN) è stata scelta la migliore, per quanto riguarda le performance ottenute sullo split di test, per poter proseguire con ulteriori test. Come possiamo notare in Tabella 6.1, la *CNN* presenta delle performance migliori rispetto alle altre due architetture proposte; inoltre la scelta è stata determinata, oltre che dalle performance, dalla grandezza della rete (riferito al peso in byte del file contenente i pesi della rete), e sotto questo punto di vista la *CNN* prevale ancora.

Dataset *original* vs *ridotto*. Con la seconda tipologia di test, si è cercato di verificare se il dataset di training ridotto (Sezione 6.2) portasse degli effettivi miglioramenti sulle prestazioni del modello. Come si può notare in Tabella 6.2, il test è stato inconcludente in quanto non si hanno miglioramenti nelle performance, anzi sono calate leggermente in alcuni casi. Questo test presenta una problematica che merita di essere evidenziata: il dataset di training è stato ripulito con lo stesso modello che stiamo

verificando, questo significa che anche se abbiamo utilizzato il test esposto nella Sezione 6.2, non possiamo essere certi che tutte le registrazioni che sono state eliminate presentassero effettivamente un malposizionamento. L'unico modo per essere certi è tramite revisione umana, per mano di cardiologi esperti, di tutto il dataset. Solo in questo modo possiamo essere sicuri di avere un dataset pulito.

Dataset esterno Con questo test è stata verificata la capacità dei modelli di generalizzare su registrazioni provenienti da un altro dataset (Sezione 4.7). In Tabella 6.3 possiamo notare come vengano riconfermate le discussioni del paragrafo precedente, dove i modelli allenati con il dataset originale performano generalmente meglio, tranne per alcune classi (le stesse in cui i modelli *reduced* avevano delle performance leggermente migliori).

Dataset esterno modificato Questo è il test principale con il quale è possibile misurare le performance effettive del modello. I risultati riportati in Tabella 6.4 mostrano un'accuratezza complessiva molto elevata in tutte le configurazioni (compresa tra il 97,98% e il 99,96%), un valore tuttavia poco informativo data la forte sproporzione tra le classi, come evidenziato dai volumi di TN in Tabella 6.5 (dell'ordine delle decine di migliaia contro poche centinaia di TP). È quindi sulla precisione, sul recall e sull' $F1$ della classe di scambio che vanno lette le reali capacità del modello.

Le configurazioni LA_LL , RA_LA , RA_LL e $V1_V2$ confermano un comportamento solido: RA_LL ottiene il miglior risultato in assoluto ($F1 \sim .978$, con recall pari a 1.0 e un numero di falsi positivi molto contenuto, 19 in tutti i seed), mentre RA_LA raggiunge anch'essa recall perfetto ma con una precisione leggermente inferiore (.93-.94), dovuta a un numero di falsi positivi lievemente più alto (29-30). LA_LL si distingue invece per l'andamento opposto: precisione molto alta (.978) ma recall più contenuto (.93-.94), segno che il modello tende in questo caso a essere predire la

classe di scambio solo quando è molto "sicuro", a scapito di qualche falso negativo (26-31).

Le configurazioni che coinvolgono le classi V2-V6 mostrano invece una forte diminuzione della precisione, pur mantenendo un recall quasi sempre pari o vicino a 1.0. Il caso più critico è V2_V3, con una precisione di appena .33 ($F1 \sim .496$) a fronte di oltre 850 falsi positivi per seed (Tabella 6.5), a indicare una forte tendenza del modello a confondere segmenti di classi adiacenti con la classe di scambio. Le configurazioni V3_V4, V4_V5 e V5_V6 seguono un andamento simile ma meno marcato, con precisione crescente al diminuire del numero di falsi positivi (rispettivamente $\sim .666$, $\sim .469$ e $\sim .38$), suggerendo che l'errore del modello sia sistematico e correlato alla vicinanza temporale/posizionale tra le classi coinvolte, più che a un problema isolato di una singola configurazione.

L'introduzione della soglia di confidenza al 90% (Tabella 6.6) conferma questa ipotesi, infatti, per tutte le configurazioni critiche si osserva un netto calo dei falsi positivi, con un miglioramento della precisione (V3_V4 passa da $\sim .666$ a $\sim .833$, V4_V5 da $\sim .469$ a $\sim .617$, V5_V6 da $\sim .38$ a $\sim .66$), a fronte di una perdita minima o nulla di recall (al più 3 falsi negativi aggiuntivi, come in V5_V6). Fa eccezione V2_V3, che pur beneficiando della soglia (precisione da $\sim .33$ a $\sim .459$) resta la configurazione più problematica, con un numero di falsi positivi ancora elevato (483); ciò conferma che la sovrapposizione tra le classi V2 e V3 rappresenta il limite più significativo del modello, non completamente risolvibile con la sola modifica della soglia di confidenza.

Confronto con lo stato dell'arte All'interno della Tabella 7.1 vengono riportate le prestazioni raggiunte dal modello proposto (configurazione *china modificato* con soglia 90% dove mostrato) a fianco dei valori riportati in letteratura dai metodi classici di analisi del segnale e da modelli di deep learning. È importante premettere che si tratta di un confronto *indicativo* e non di un benchmark diretto: i lavori citati utilizzano database, protocolli di simulazione dello scambio e definizioni di "successo" (per singolo battito,

per finestra temporale o per intera registrazione) differenti tra loro e rispetto a quanto utilizzato in questa tesi; inoltre alcune metriche in letteratura sono aggregate su più tipologie di scambio contemporaneamente.

Tabella 7.1: Confronto tra il modello proposto alcuni riferimenti di letteratura

Riferimento	Tipo di metodo	Classe/i	Metrica principale
Hedén et al. [13]	ANN (storica)	RA-LA	Sp≈99.9%, Se≈98.7%
Kors & van Herpen [22]	Correlazione derivazioni	RA-LA/RA-LL	Se≥93%, Sp≥99.5%
Kors & van Herpen [22]	Correlazione derivazioni	LA-LL	Se=17.9%
Jekova et al. [18]	Correlazione interlead	Precordiali (1-3 hop)	Se=99.52%, Sp=99.62%
Jekova et al. [18]	Correlazione interlead	Periferiche	Se=92.10%, Sp=96.05%
Rjoob et al. [35]	Deep learning (BLSTM)	V1/V2	Acc.=93.0%
Huang et al. [15]	Deep learning (lightweight)	arti+precordiali (12 casi)	Macro F1 93.42-99.61%
Alves et al. [2]	Deep learning (CNN+RNN)	RA-LA, RA-LL	metriche ≥0.96
Alves et al. [2]	Deep learning (CNN+RNN)	Precordiali	metriche >0.86
Questo lavoro	CNN	RA_LL	F1=0.978
Questo lavoro	CNN	RA_LA	F1=0.966
Questo lavoro	CNN	LA_LL	F1=0.957
Questo lavoro	CNN	V1_V2	F1=0.943
Questo lavoro (soglia 90%)	CNN	V3_V4	Precisione=0.833
Questo lavoro (soglia 90%)	CNN	V2_V3	Precisione=0.459

Tabella 7.2: Confronto tra il modello proposto (Se/Sp, seed 42) e alcuni riferimenti di letteratura

Riferimento	Tipo di metodo	Classe/i	Se	Sp
Hedén et al. [13]	ANN (storica)	RA-LA	$\approx 98.7\%$	$\approx 99.9\%$
Kors & van Herpen [22]	Correlazione derivazioni	RA-LA/RA-LL	$\geq 93\%$ (stimato)	$\geq 99.5\%$
Kors & van Herpen [22]	Correlazione derivazioni	LA-LL	17.9%	n.d.
Jekova et al. [18]	Correlazione inter-lead	Precordiali (1-3 hop)	99.52%	99.62%
Jekova et al. [18]	Correlazione inter-lead	Periferiche	92.10%	96.05%
Questo lavoro	CNN	LA_LL	93.62%	99.98%
Questo lavoro	CNN	RA_LA	100.00%	99.93%
Questo lavoro	CNN	RA_LL	100.00%	99.95%
Questo lavoro	CNN	V1_V2	99.29%	99.89%
Questo lavoro	CNN	V2_V3	99.53%	97.97%
Questo lavoro	CNN	V3_V4	98.82%	99.50%
Questo lavoro	CNN	V4_V5	100.00%	98.86%
Questo lavoro	CNN	V5_V6	99.29%	98.38%

Sulle classi periferiche (RA_LA, RA_LL, LA_LL), il modello proposto si colloca in linea con i risultati più recenti basati su deep learning (Alves et al. [2]) e supera nettamente il limite storico dei metodi classici sulla classe LA_LL, dove Kors e van Herpen [22] riportavano una sensibilità di appena il 17.9%: la rete convoluzionale qui proposta raggiunge invece un F1 di 0.957, con precisione e recall entrambi superiori al 92%. Questo suggerisce che l'approccio basato su rappresentazioni apprese dal segnale grezzo, rispetto a regole di correlazione fissate a priori, sia particolarmente efficace proprio sui casi in cui i metodi classici mostravano più difficoltà.

Sulle classi precordiali adiacenti (in particolare V2_V3), il confronto è invece meno favorevole: Jekova et al. [18] riportano sensibilità e specificità superiori al 99% per gli scambi precordiali, molto migliore rispetto alla precisione ottenuta dal modello proposto su questa classe (anche dopo la modifica della soglia di confidenza). Va tuttavia notato che il metodo di Jekova et al. sfrutta esplicitamente la struttura di correlazione nota tra derivazioni precordiali adiacenti, un'informazione strutturale che nel presente

lavoro non viene fornita esplicitamente al modello ma dev'essere appresa implicitamente dai dati; questo potrebbe spiegare, almeno in parte, la netta differenza tra i risultati e suggerisce una possibili idea di miglioramento futuro (ad esempio incorporando vincoli o feature basate sulla correlazione inter-derivazione).

Capitolo 8

Conclusioni e sviluppi futuri

In questo capitolo conclusivo vengono riassunti i principali risultati ottenuti nel corso del lavoro di tesi, evidenziando i contributi apportati e i limiti riscontrati; vengono infine esposte alcune possibili direzioni di sviluppo futuro.

8.1 Conclusioni

Il lavoro presentato in questa tesi ha affrontato il problema del riconoscimento automatico di scambi di elettrodi nell’acquisizione di tracciati ECG, un errore comune in ambito clinico che può compromettere l’interpretazione diagnostica del segnale. È stata sviluppata una pipeline completa, che comprende la costruzione e la pulizia del dataset di training, l’addestramento di diverse architetture di rete neurale e una metodologia di valutazione a livello di intera registrazione basata su majority voting, più robusta rispetto a una valutazione sul singolo battito.

Il confronto tra le tre architetture proposte (MLP, CNN, GCN) ha evidenziato come la CNN rappresenti la scelta più efficace, sia in termini di accuratezza sia di dimensione del modello, risultando infatti nell’architettura di riferimento per tutti i test successivi.

Il tentativo di migliorare la qualità del training set attraverso la rimozione delle registrazioni potenzialmente etichettate in modo errato (variante *reduced*) non ha prodotto un miglioramento sistematico delle prestazioni rispetto al dataset *original*. Come discusso, questo risultato è in parte attribuibile al fatto che la procedura di pulizia si basa sullo stesso modello oggetto di valutazione, un limite che può essere superato solo attraverso una revisione umana da parte di cardiologi esperti.

La validazione su un dataset esterno (*China*) ha permesso di verificare la capacità dei modelli di generalizzare su una popolazione e un protocollo di acquisizione differenti da quelli visti in training, confermando complessivamente la maggiore solidità dei modelli allenati sul dataset originale.

Il test più significativo condotto in questa tesi resta quello sul dataset esterno modificato, in cui è stata simulata artificialmente una percentuale nota di scambi di elettrodi. I risultati hanno mostrato che il sistema è in grado di identificare con ottima precisione e recall gli scambi che coinvolgono le derivazioni degli arti e il caso V1_V2, mentre le prestazioni calano sensibilmente per gli scambi tra derivazioni precordiali adiacenti (V2_V3 peggiori performance), a causa di una forte tendenza del modello a confondere segmenti di classi adiacenti con la classe di scambio. L'introduzione di una soglia di confidenza più elevata si è dimostrata una strategia efficace per ridurre, senza tuttavia risolvere del tutto, questo problema.

Nel complesso, il sistema sviluppato dimostra che un approccio basato su reti neurali convoluzionali applicate al segnale ECG è in grado di rilevare in modo affidabile la maggior parte degli scambi di elettrodi più clinicamente rilevanti, pur presentando margini di miglioramento evidenti tra derivazioni precordiali vicine tra loro.

8.2 Sviluppi futuri

Sulla base dei risultati ottenuti e dei limiti individuati, si possono identificare diverse direzioni per estendere il presente lavoro:

- **Revisione clinica del dataset.** Per superare il limite metodologico discusso a proposito della pulizia del training set, sarebbe opportuno sottoporre le registrazioni candidate a una revisione da parte di cardiologi esperti, in modo da ottenere un dataset *reduced* realmente validato e verificare se questo porti a un miglioramento effettivo delle prestazioni.
- **Miglioramento della distinzione tra derivazioni precordiali adiacenti.** Il calo di precisione osservato per le configurazioni V2_V3, V3_V4, V4_V5 e V5_V6 suggerisce la necessità di introdurre feature aggiuntive o rappresentazioni del segnale più informative (ad esempio basate sulla morfologia dell'onda R o su trasformazioni tempo-frequenza) in grado di catturare meglio le differenze geometriche tra derivazioni precordiali adiacenti.
- **Modello multi-classe unificato.** L'attuale approccio prevede modelli distinti per ciascuna coppia di derivazioni; un possibile sviluppo consiste nella progettazione di un singolo modello in grado di riconoscere simultaneamente tutte le tipologie di scambio, valutandone i vantaggi in termini di semplicità di deployment e le eventuali perdite di prestazioni rispetto ai modelli specializzati. Un'altra soluzione può essere la creazione di due modelli multi-classe: uno per le derivazioni periferiche e l'altro per le precordiali; in modo da poter concentrare ogni modello su riconoscimenti affini.
- **Soglia di confidenza adattiva.** I risultati ottenuti con la soglia al 90% mostrano un buon compromesso tra precisione e recall per le classi più critiche; un possibile sviluppo è la definizione di soglie ottimizzate per singola classe, eventualmente determinate in modo automatico a partire dalle curve precision-recall.

- **Estensione a ulteriori dataset esterni.** Per rafforzare la valutazione della capacità di generalizzazione del sistema, sarebbe utile testare i modelli su ulteriori dataset pubblici, provenienti da popolazioni, dispositivi di acquisizione e protocolli clinici differenti da quelli già considerati.
- **Integrazione in ambito clinico.** Infine, un possibile sviluppo applicativo consiste nell'integrazione del sistema come modulo di controllo qualità in tempo reale all'interno dei software di acquisizione ECG, in grado di segnalare in tempo reale al personale sanitario un probabile errore di posizionamento degli elettrodi prima della refertazione del tracciato.

Bibliografia

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD)*, pages 2623–2631, 2019.
- [2] Isac A. Alves, Gabriela M. M. Paixão, Paulo R. Gomes, Jessyca A. Bessa, Antônio Luiz P. Ribeiro, and Jermana L. Moraes. Deep learning models for real-world detection of electrode interchange in 12-lead ECGs: A telecardiology validation. In *Proceedings of the Brazilian Congress on Artificial Intelligence (CBIC)*, 2025.
- [3] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization, 2016.
- [4] J. J. Bailey, A. S. Berson, A. Garson, L. G. Horan, P. W. Macfarlane, D. W. Mortara, and C. Zywietz. Recommendations for standardization and specifications in automated electrocardiography: bandwidth and digital signal processing. *Circulation*, 81(2):730–739, 1990.
- [5] Velislav N. Batchvarov, Marek Malik, and A. John Camm. Incorrect electrode cable connection during electrocardiographic recording. *Europace*, 9(11):1081–1090, 2007.
- [6] Stephen Butterworth. On the theory of filter amplifiers. *Experimental Wireless and the Wireless Engineer*, 7:536–541, 1930.

- [7] Tyler Derr, Yao Ma, and Jiliang Tang. Signed graph convolutional networks. In *IEEE International Conference on Data Mining (ICDM)*, pages 929–934, 2018.
- [8] Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000.
- [9] Ary L. Goldberger, Zachary D. Goldberger, and Alexei Shvilkin. *Goldberger’s Clinical Electrocardiography: A Simplified Approach*. Elsevier, 9th edition, 2017.
- [10] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [11] Chao Han, Richard E. Gregg, David Q. Feild, and Saeed Babaeizadeh. Automatic detection of ECG cable interchange by analyzing both morphology and interlead relations. *Journal of Electrocardiology*, 47(6):781–787, 2014.
- [12] Awni Y. Hannun, Pranav Rajpurkar, Masoumeh Haghpanahi, Geoffrey H. Tison, Codie Bourn, Mintu P. Turakhia, and Andrew Y. Ng. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature Medicine*, 25(1):65–69, 2019.
- [13] Björn Hedén, Mattias Ohlsson, Lars Edenbrandt, Ralf Rittner, Olle Pahlm, and Carsten Peterson. Artificial neural networks for recognition of electrocardiographic lead reversal. *American Journal of Cardiology*, 75(14):929–933, 1995.
- [14] Kim K. Ho and Simon K. Ho. Use of the sinus P wave in diagnosing electrocardiographic limb lead misplacement not involving the right leg (ground) lead. *Journal of Electrocardiology*, 34(2):161–171, 2001.

- [15] Yangcheng Huang, Mingjie Wang, Yi-Gang Li, and Wenjie Cai. A lightweight deep learning approach for detecting electrocardiographic lead misplacement. *Physiological Measurement*, 45(5):055006, 2024.
- [16] Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, volume 37 of *PMLR*, pages 448–456, 2015.
- [17] Irena Jekova, Vessela Krasteva, Remo Leber, Ramun Schmid, and Roger Abächerli. Detection of electrode interchange in right precordial and posterior ECG leads. In *2015 Computing in Cardiology Conference (CinC)*, pages 1149–1152. IEEE, 2015.
- [18] Irena Jekova, Vessela Krasteva, Remo Leber, Ramun Schmid, Raphael Twerenbold, Christian Müller, Tobias Reichlin, and Roger Abächerli. Inter-lead correlation analysis for automated detection of cable reversals in 12/16-lead ECG. *Computer Methods and Programs in Biomedicine*, 134:31–41, 2016.
- [19] Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. In *International Conference on Learning Representations (ICLR)*, 2017.
- [20] Paul Kligfield, Leonard S. Gettes, James J. Bailey, Rory Childers, Barbara J. Deal, E. William Hancock, Gerard van Herpen, Jan A. Kors, Peter Macfarlane, David M. Mirvis, et al. Recommendations for the standardization and interpretation of the electrocardiogram: Part I: The electrocardiogram and its technology. *Circulation*, 115(10):1306–1324, 2007.
- [21] Jan A. Kors and Gerard van Herpen. A novel method to detect electrocardiographic electrode interchanges. *Journal of Electrocardiology*, 33:209–210, 2000.
- [22] Jan A. Kors and Gerard van Herpen. Accurate automatic detection of electrode interchange in the electrocardiogram. *American Journal*

- of Cardiology*, 88(4):396–399, 2001.
- [23] Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
 - [24] Andrew L. Maas, Awni Y. Hannun, and Andrew Y. Ng. Rectifier nonlinearities improve neural network acoustic models. In *ICML Workshop on Deep Learning for Audio, Speech and Language Processing*, 2013.
 - [25] Jaakko Malmivuo and Robert Plonsey. *Bioelectromagnetism: Principles and Applications of Bioelectric and Biomagnetic Fields*. Oxford University Press, New York, 1995.
 - [26] Harry Nyquist. Certain topics in telegraph transmission theory. *Transactions of the American Institute of Electrical Engineers*, 47(2):617–644, 1928.
 - [27] Alan V. Oppenheim and Ronald W. Schaffer. *Discrete-Time Signal Processing*. Prentice Hall, 2nd edition, 1999.
 - [28] Alan V. Oppenheim, Alan S. Willsky, and S. Hamid Nawab. *Signals and Systems*. Prentice Hall, 2nd edition, 1996.
 - [29] Jiapu Pan and Willis J. Tompkins. A real-time QRS detection algorithm. *IEEE Transactions on Biomedical Engineering*, BME-32(3):230–236, 1985.
 - [30] Thomas W. Parks and James H. McClellan. Chebyshev approximation for nonrecursive digital filters with linear phase. *IEEE Transactions on Circuit Theory*, 19(2):189–194, 1972.
 - [31] Amal Paul and John Roshan Jacob. Electrocardiographic lead reversals. *Indian Pacing and Electrophysiology Journal*, 23(6):205–213, 2023.

- [32] Erick A. Perez Alday, Annie Gu, Amit J. Shah, Chad Robichaux, An-Kwok Ian Wong, Chengyu Liu, Feifei Liu, Ali Bahrami Rad, Andoni Elola, Salman Seyedi, Qiao Li, Ashish Sharma, Gari D. Clifford, and Matthew A. Reyna. Classification of 12-lead ECGs: the PhysioNet/computing in cardiology challenge 2020. *Physiological Measurement*, 41(12):124003, 2020.
- [33] Khaled Rjoob, Raymond Bond, Dewar Finlay, Victoria McGilligan, Stephen J. Leslie, Aleeha Iftikhar, Daniel Guldenring, Ali Rababah, Charles Knoery, Anne McShane, et al. Data driven feature selection and machine learning to detect misplaced V1 and V2 chest electrodes when recording the 12-lead electrocardiogram. *Journal of Electrocardiology*, 57:39–43, 2019.
- [34] Khaled Rjoob, Raymond Bond, Dewar Finlay, Victoria McGilligan, Stephen J. Leslie, Ali Rababah, Daniel Guldenring, Aleeha Iftikhar, Charles Knoery, Anne McShane, and Aaron Peace. Machine learning techniques for detecting electrode misplacement and interchanges when recording ECGs: A systematic review and meta-analysis. *Journal of Electrocardiology*, 62:116–123, 2020.
- [35] Khaled Rjoob, Raymond Bond, Dewar Finlay, Victoria McGilligan, Stephen J. Leslie, Ali Rababah, Aleeha Iftikhar, Daniel Guldenring, Charles Knoery, Anne McShane, and Aaron Peace. Reliable deep learning-based detection of misplaced chest electrodes during electrocardiogram recording: Algorithm development and validation. *JMIR Medical Informatics*, 9(4):e25347, 2021.
- [36] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [37] Claude E. Shannon. Communication in the presence of noise. *Proceedings of the IRE*, 37(1):10–21, 1949.

- [38] Leif Sörnmo and Pablo Laguna. *Bioelectrical Signal Processing in Cardiac and Neurological Applications*. Academic Press, 2005.
- [39] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958, 2014.
- [40] Michael Unser. Splines: A perfect fit for signal and image processing. *IEEE Signal Processing Magazine*, 16(6):22–38, 1999.
- [41] Patrick Wagner, Nils Strodthoff, Ralf-Dieter Bousseljot, Dieter Kreiseler, Fatima I. Lunze, Wojciech Samek, and Tobias Schaeffter. PTB-XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7:154, 2020.
- [42] Jianwei Zheng, Hangyuan Guo, and Huimin Chu. A large scale 12-lead electrocardiogram database for arrhythmia study. PhysioNet, version 1.0.0, 2022.
- [43] Jianwei Zheng, Jianming Zhang, Sidy Danioko, Hai Yao, Hangyuan Guo, and Cyril Rakovski. A 12-lead electrocardiogram database for arrhythmia research covering more than 10,000 patients. *Scientific Data*, 7:48, 2020.